# Azure Batch AI

## Multi Host, Multi GPU Deep Learning PaaS HOL

(with Tensorflow, CNTK, Keras, Horovod, etc)

2018.1.27

김훈동

# 사전 준비

- https://github.com/hoondongkim/azure-batch-ai-hol
  - pre-install 및 HOL 가이드.docx 다운로드
  - (5) 소스 다운로드 전까지의 기본 Install 을 미리 해봅시다.
    - Anaconda, Tensorflow , Keras , Jupyter 등의 환경 세팅 과정입니다.
    - 기 설치 하신 분들은 설치하지 않으셔도 무방합니다.
    - 가이드 문서 데로 설치 시 이상이 있는 분들은 손을 들고 문의 주세요.

[진행순서]

1시~1시 40분 : 위 사전 준비 완료

1시 40분 ~2시 10분 : 이론 설명

2시 20분 ~ 3시 20분 : Deep Learning 로컬 수행

3시 30분 ~ 4시 20분 : Azure Batch AI 준비

4시 30분 ~ 5시 30분 : Azure Batch AI 수행

5시 30분 이후 : 결론 및 마무리

- 김훈동
- 스사모(Korea Spark User Group) 운영진
- 신세계 그룹 온라인 포털 SSG.COM 빅데이타파트 리더
- Hadoop, Spark, Machine Learning, Azure ML 분야
  Microsoft MVP(Most Valuable Professional)
- http://hoondongkim.blogspot.kr
- hoondongkim@gmail.com
- https://www.facebook.com/kim.hoondong

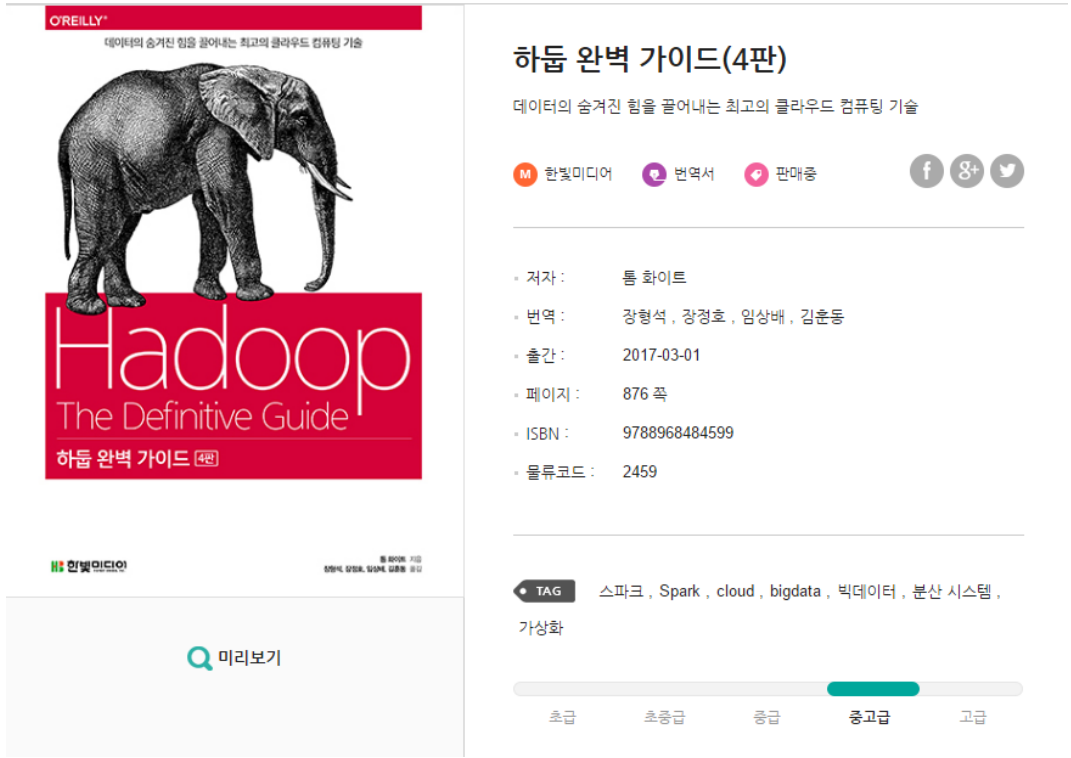

# Data Science 에 적합한 개발 방법론

- Agile & 나선형 접근이 유리
- But, 소개하는 아키텍처는 정답도 아니고, 정답이 존재 하지도 않음.
- 구현 & Test & 적용 & 확인 & 변경 & 진화 의 반복.

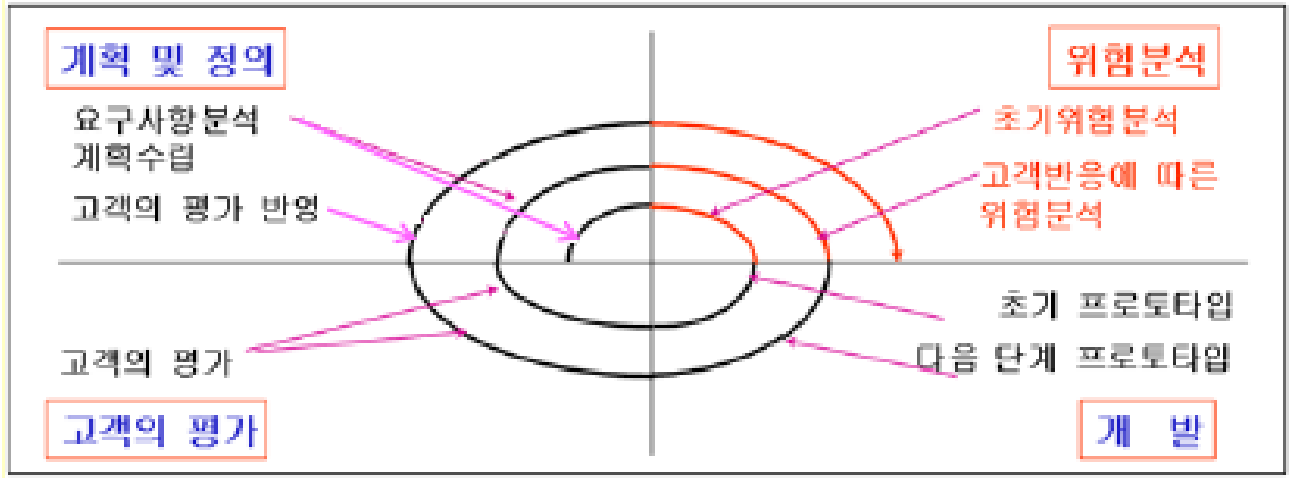

# 들어가며

흔한
최신 스타일
개발
Approach

2. 이 부분의
조금 쉽고 간편하
고 안전한, 접근
방법 없나?

1. 이 부분의
Pain Point &
해결방법

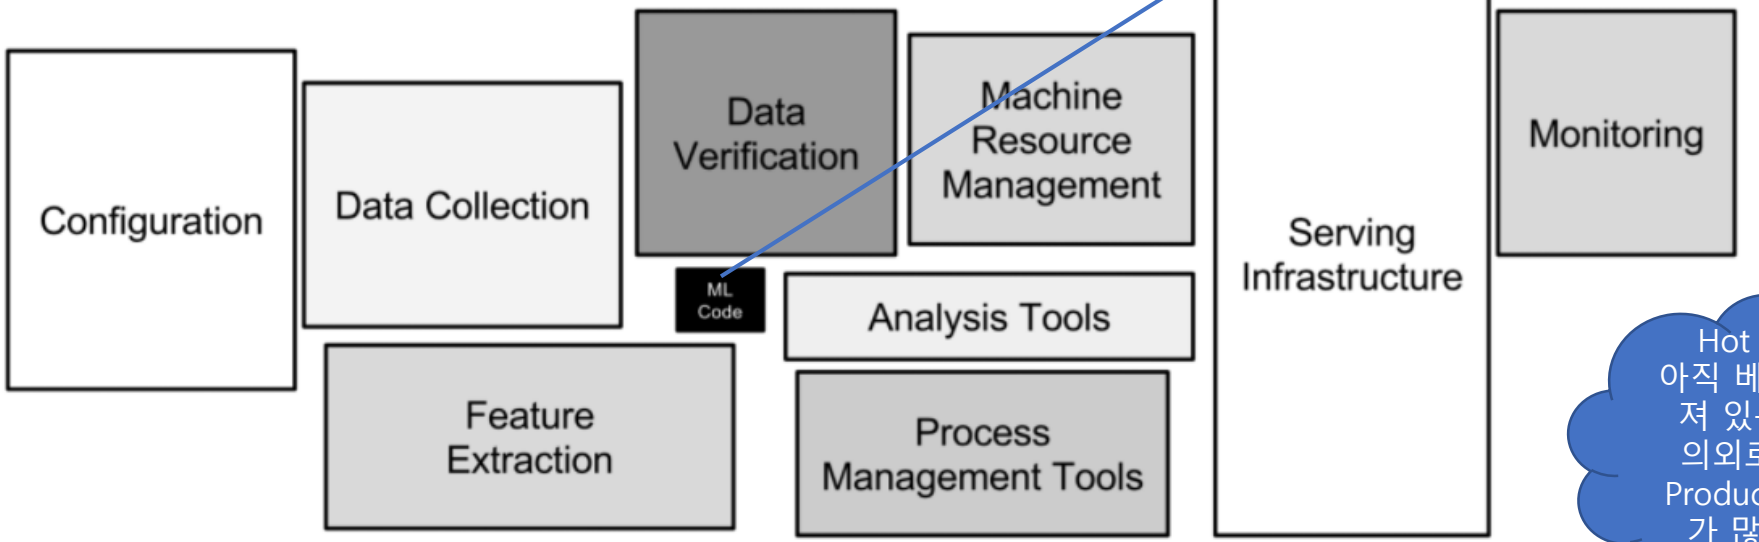


Hot 하지만,
아직 베일에 가려
져 있는 영역...
의외로 국내엔
Production 사례
가 많지 않음.

*Only a tiny fraction of the code in many ML systems is actually devoted to learning or prediction.*

Schulley et al, Hidden Technical Debt in Machine Learning Systems, In NIPS 2015.

# 1. Deep Learning 프로젝트 Pain Point 및 그 해결 방법

# 무엇이 문제 인가?

- 우리는 논문을 쓰는 것이 아님.
- 우리의 문제는 한두가지가 아님.

# ChatBot(엔터프라이즈 급....)을 예로 들어 보자...

Depth 1 : Intent Classifier

Depth 2 : Sequential Dialog Node Classifier

Depth 3 : Named Entity Recognition

Depth 4 : Rule Base Dialog

Depth 5 : Wide Mdoel Classifier

Depth 6 : Generative Model

Pre-Processing

- Word Representation Layer
- Entity Dictionary
- Item2Vec

Serving

- Graph DB
- Search & NoSQL
- Deep Learning Serving
- Real-Time inference

논문으로 치면, 10개 이상의 주제
영역이 결합한 복합 문제임.

# 10여개 중 1개 – Depth 1 (Intent Classifier 정확도) 예시

| | | |
|---|---|---|
| 1. | Word2Vec + CNN (Batch Normalize + Augmentation) | 72.30% |
| 2. | Word2Vec + LSTM | 73.94% |
| 3. | Word2Vec + CNN + LSTM | 72.97% |
| 4. | Word2Vec + Bidirectional GRU | 74.36% |
| 5. | Word2Vec + Bidirectional GRU + Attention Network | 73.15% |
| 6. | FastText | 72.50% |
| 7. | Glove + LSTM (BigDL on Spark Cluster) | 75.25% |

# 그럼 어떻게 접근해야 하는가?

하나의 주제를 논문 쓰듯 파고 들
어서는 안됨.

그 주제에 대한 현존 State of The Art 논문 중
반년 이상 시간이 지난(구현체가 검증이 필요한 최소 기간)
알고리즘을 최소 3개 ~ 5,6개(적당) 정도를 선정하고,

**빠르게 구현 -> Our 데이터로 테스트 -> 최적의 알고리즘 선정**

With 검증된
DataSet 으로...

Custom
Parameter Tuning

각종 전처리, Data
뿔리기, 후처리

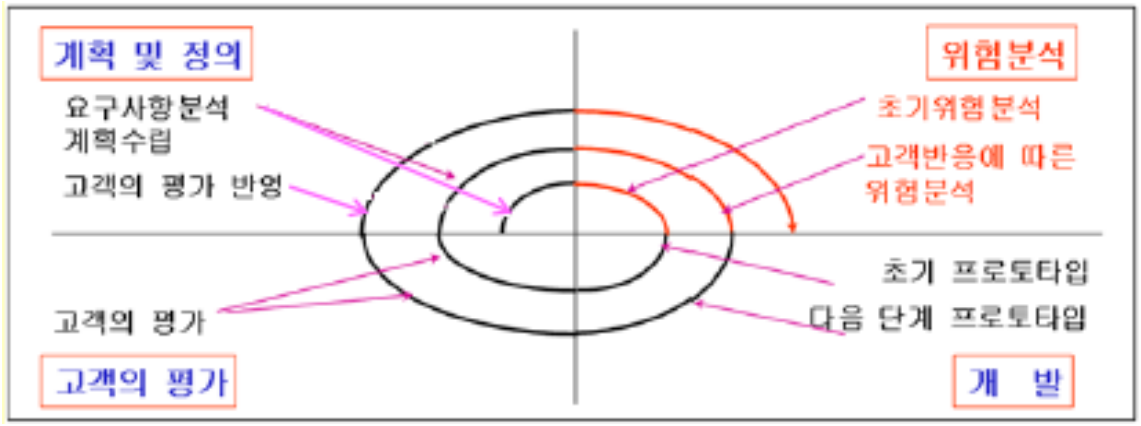


# 빠른 구현 및 테스트 능력 중요!

Keras 등 High Level Deep Learning 스킬 사용 권장 ~~~~ (for Agile...)

그 과정을 10번 정도
거쳐야 함.

10개 문제 * 5개(State Of the Art)
= 50개 정도 알고리즘 테스트

하나의 Deep Learning 알고리즘은, Hyper Parameter 나 각종 옵션을, 최소 6번 정도 Test 하고 검증 하며 최적화 해야함.

10개 문제 * 5개(State Of the Art) * 6개(Hyper Parameter 최적화) = 300번 정도 Deep Learning 수행

# Deep Learning 은 고행인가?

- One of the Good Score is Word2Vec + Bidirectional GRU
- Tesla M40 GPU
- Training Data 165만 건
- Learning Rate 0.0005

- seq2seq
- Tesla K80 * 2
- 165만 건
- 약 24시간

```
Epoch 1/5
1649415/1649415 [==============================] - 10174s - loss: 1.0124 - acc: 0.6992 - val_loss: 0.9239 -
Epoch 2/5
1649415/1649415 [==============================] - 9949s - loss: 0.9461 - acc: 0.7157 - val_loss: 0.9076 -
Epoch 3/5
1649415/1649415 [==============================] - 9951s - loss: 0.9318 - acc: 0.7199 - val_loss: 0.9068 -
Epoch 4/5
1649415/1649415 [==============================] - 9953s - loss: 0.9234 - acc: 0.7220 - val_loss: 0.9039 -
Epoch 5/5
1649415/1649415 [==============================] - 9962s - loss: 0.9176 - acc: 0.7241 - val_loss: 0.9079 - val_acc
: 0.7436
tail: keras_output.txt: file truncated
```

- 5 Epoch 에 50000초 = 833분 = 약 14시간

# Training 속도에 대하여

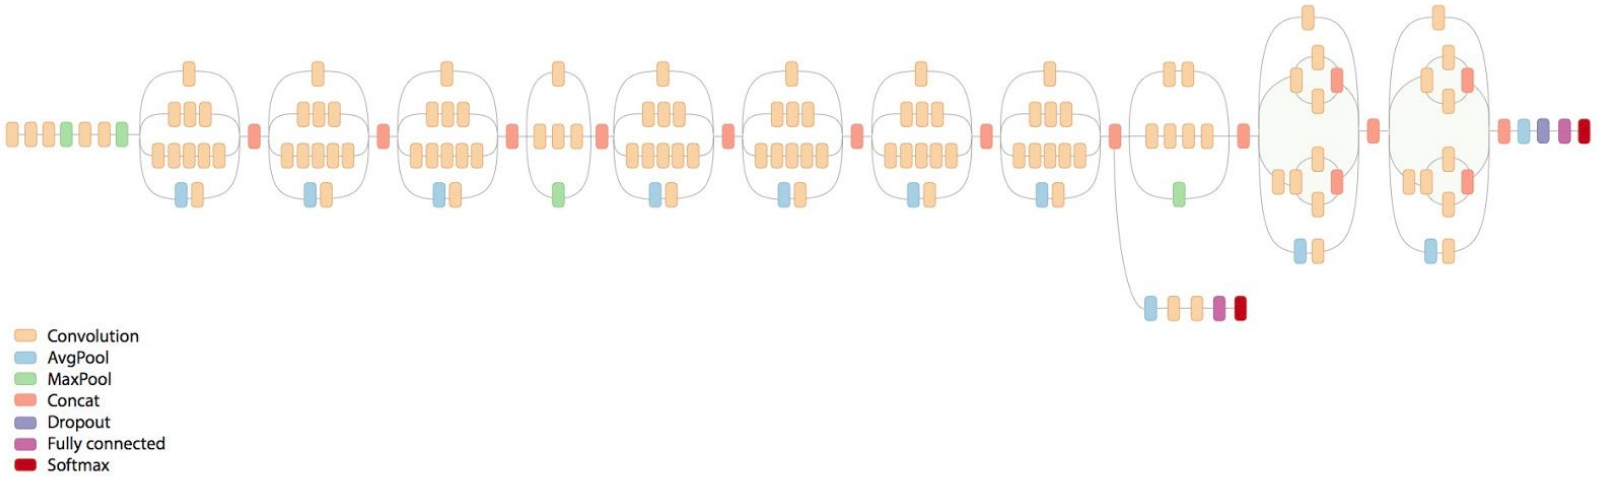


- 이미지와 달리 Text NLP 등은 오픈 된 Pre training Set 이 거의 없음.
- 이미지의 경우에도 실무에서는 정확도를 올리기 위해 Fine Tuning 하는 경우가 많음.
- 깊은 층의 모델로 학습시키는 경우 어마어마한 시간이 걸림.
- 상품갯수 200만건, 이미지 2000만건??

# 속도에 대한 해결 방법(용량 문제는 일단 보류)

- Multi GPU Programming

## MULTI-GPU TRAINING (SINGLE NODE)

- Variables stored on CPU (`cpu:0`)
- Model graph (aka "replica", "tower") is copied to each GPU (`gpu:0`, `gpu:1`, ...)

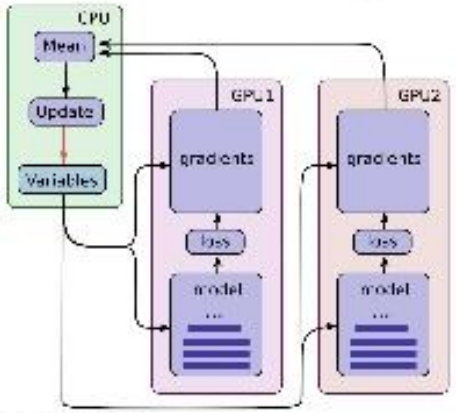


**Multi-GPU Training Steps:**

1. CPU transfers model to each GPU
2. CPU waits on all GPUs to finish batch
3. CPU copies all gradients back from all GPUs
4. CPU synchronizes and averages all gradients from GPUs
5. CPU updates GPUs with new variables/weights
6. Repeat Step1 until reaching stop condition (ie. `max_epochs`)

# 가끔 문제를 해결하기 위한 도구가, 문제를 더 복잡하게 만든다.

- Multi GPU Programming & Multi Host Programming
- 마치 4~5년 전 Map/Reduce Programming 문제를 보는 듯 한…

- 그래도 해야 한다면… 아래와 같은 것들 잘 활용…
  - config.gpu_options.per_process_gpu_memory_fraction = 0.4
  - allow_soft_placement = True 옵션
  - tf.FIFOQueue , tf.train.queue_runner (for I/O 나 input Pipeline 병목)
  - data_flow_ops.RecordInput (for Parallelize I/O)
  - tf.parallel_stack (예, concat 대신 요거… for 병렬 프로세싱)
  - data_flow_ops.StaingArea (for Parallel cpu to gpu data transfer)

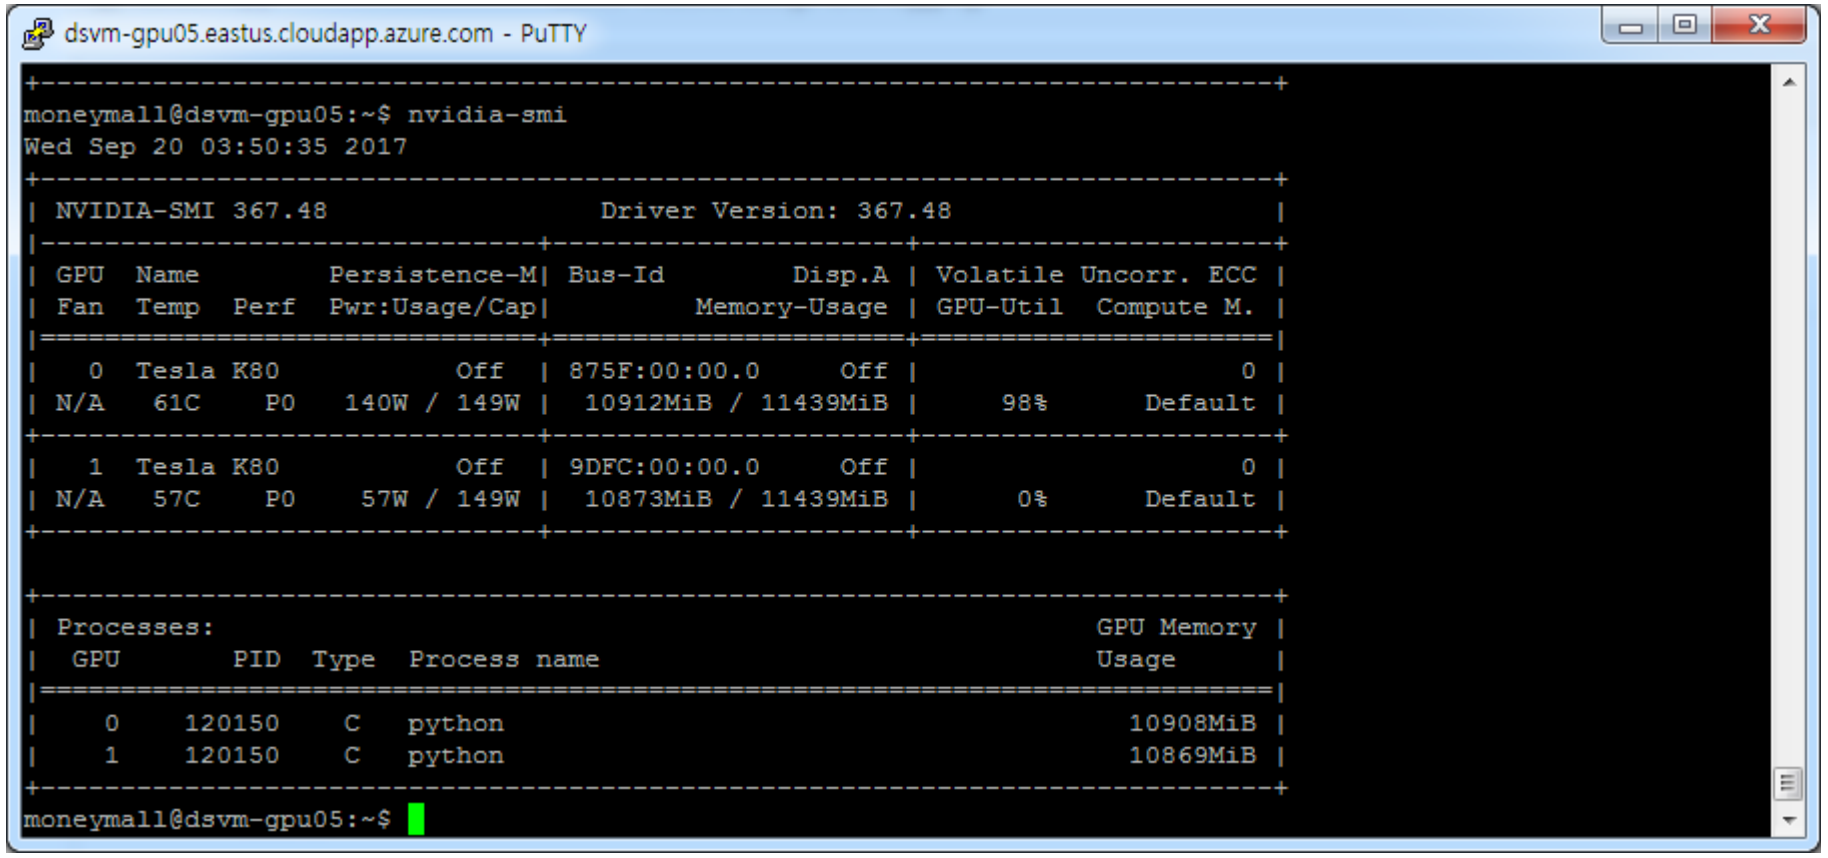


But, 요런거는 쉽게 가능 : os.environ["CUDA_VISIBLE_DEVICES"]="0"
2017년 10월 경 업데이트로 Keras Multi GPU도 꽤 편해졌다.(Not Multi Host)

# 성능을 쥐어 짜듯 끌어 올리기.

- Drop Out 대신 Batch Normalization
- GPU 에서는 NCHW , CPU 에서는 종종 NHWC 가 더 빠름.
- tf.contrib.layers.batch_norm 안에는 fused batch-normalization 구현되어 있음. (GPU 에서는 종종 훨씬 빠름)

```
bn = tf.contrib.layers.batch_norm(
        input_layer, fused=True, data_format='NCHW'
        scope=scope)
```

# Multi Host Programming

- Parameter_server
- Replicated
- Distributed_replicated

- tf.contrib.nccl
  (for 멀티 GPU borad cast 변수 및 gradient 집계)

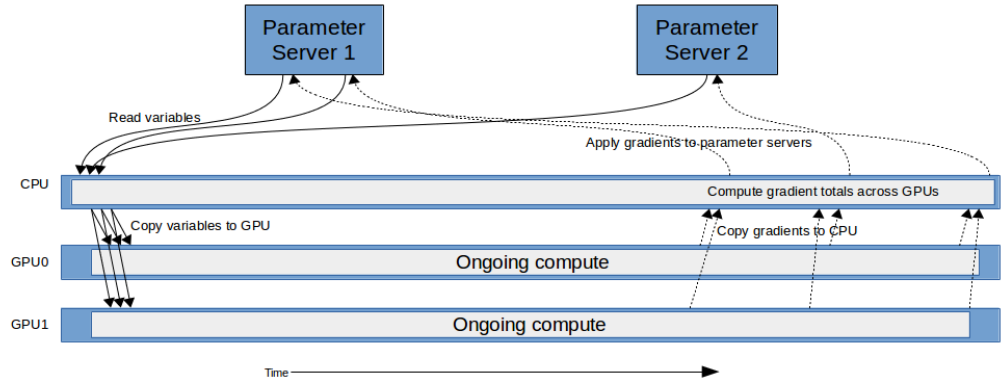


Single worker's view of variable reads and updates in parameter_server mode, with three variables.

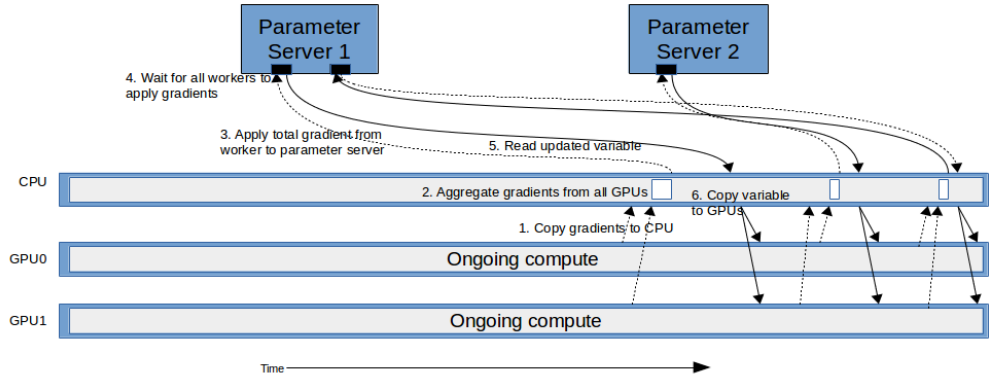


Single worker's view of variable reads and updates in distributed_replicated mode, with three variables.
Ordered steps are numbered; these steps are applied for each variable.

# Multi GPU & Single Host example

```
# VGG16 training ImageNet with 8 GPUs using arguments that optimize for
# Google Compute Engine.
python tf_cnn_benchmarks.py --local_parameter_device=cpu --num_gpus=8 \
--batch_size=32 --model=vgg16 --data_dir=/home/ubuntu/imagenet/train \
--variable_update=parameter_server --nodistortions

# VGG16 training synthetic ImageNet data with 8 GPUs using arguments that
# optimize for the NVIDIA DGX-1.
python tf_cnn_benchmarks.py --local_parameter_device=gpu --num_gpus=8 \
--batch_size=64 --model=vgg16 --variable_update=replicated --use_nccl=True

# VGG16 training ImageNet data with 8 GPUs using arguments that optimize for
# Amazon EC2.
python tf_cnn_benchmarks.py --local_parameter_device=gpu --num_gpus=8 \
--batch_size=64 --model=vgg16 --variable_update=parameter_server

# ResNet-50 training ImageNet data with 8 GPUs using arguments that optimize for
# Amazon EC2.
python tf_cnn_benchmarks.py --local_parameter_device=gpu --num_gpus=8 \
--batch_size=64 --model=resnet50 --variable_update=replicated --use_nccl=False
```

# Multi Host example

```
# Run the following commands on host_0 (10.0.0.1):
python tf_cnn_benchmarks.py --local_parameter_device=gpu --num_gpus=8 \
--batch_size=64 --model=resnet50 --variable_update=distributed_replicated \
--job_name=worker --ps_hosts=10.0.0.1:50000,10.0.0.2:50000 \
--worker_hosts=10.0.0.1:50001,10.0.0.2:50001 --task_index=0

python tf_cnn_benchmarks.py --local_parameter_device=gpu --num_gpus=8 \
--batch_size=64 --model=resnet50 --variable_update=distributed_replicated \
--job_name=ps --ps_hosts=10.0.0.1:50000,10.0.0.2:50000 \
--worker_hosts=10.0.0.1:50001,10.0.0.2:50001 --task_index=0

# Run the following commands on host_1 (10.0.0.2):
python tf_cnn_benchmarks.py --local_parameter_device=gpu --num_gpus=8 \
--batch_size=64 --model=resnet50 --variable_update=distributed_replicated \
--job_name=worker --ps_hosts=10.0.0.1:50000,10.0.0.2:50000 \
--worker_hosts=10.0.0.1:50001,10.0.0.2:50001 --task_index=1

python tf_cnn_benchmarks.py --local_parameter_device=gpu --num_gpus=8 \
--batch_size=64 --model=resnet50 --variable_update=distributed_replicated \
--job_name=ps --ps_hosts=10.0.0.1:50000,10.0.0.2:50000 \
--worker_hosts=10.0.0.1:50001,10.0.0.2:50001 --task_index=1
```

구현이 되어 있는 일부를 제외하고,
구현 안되어 있는 것들은??

LSTM의
여러 파생
들은...

유명한 일부 CNN 구현체들 빼고는 구현된 것들이 별로 없음.
LSTM , GRU, bi-Drectional , GAN,
seq2seq , charRNN , DQN

# 타사 극복 사례

- GPU Resource Unbalance 문제
- GPU Node Scale Out 문제

사례 소개

- High Level Approach
- Low Level Approach
  - S사
  - K사

# SKT

## NVIDIA DEEP LEARNING SDK UPDATE

Up to 3x Faster Deep Learning on Volta

### GPU-accelerated DL Primitives

cuDNN 7

**2.5x** Faster Training of CNNs for computer vision

**3x** Faster Training of RNNs for speech and machine translations

Leading frameworks support

### Multi-GPU & Multi-node

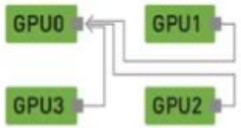


NCCL 2

Multi-node distributed training on up-to 8 servers

Near-linear scaling on PCIe and Nvink interconnect

Leading frameworks support

### Inference Optimizer and Runtime Engine

TensorRT 3

**3.5x** Faster Inference

Optimize TensorFlow or Caffe trained models

Linux, Windows, QNX and Android support

# SKT

## NVIDIA Collective Communications Library (NCCL) 2

Multi-GPU and multi-node collective communication primitives

High-performance multi-GPU and multi-node collective communication primitives optimized for NVIDIA GPUs

Fast routines for multi-GPU multi-node acceleration that maximizes inter-GPU bandwidth utilization

Easy to integrate and MPI compatible. Uses automatic topology detection to scale HPC and deep learning applications over PCIe and NVink

Accelerates leading deep learning frameworks such as Caffe2, Microsoft Cognitive Toolkit, MXNet, PyTorch and more

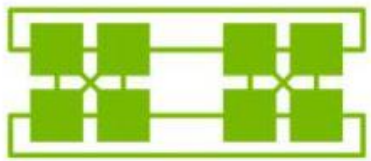

Multi-GPU:
NVLink
PCIe

Multi-Node:
InfiniBand verbs
IP Sockets

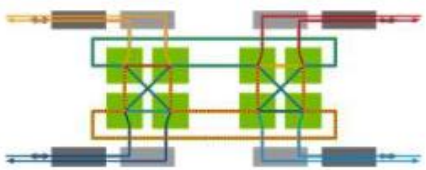

Automatic
Topology
Detection

developer.nvidia.com/nccl

# SKT

## NCCL: MULTI-GPU AND MULTI-NODE SCALING

### 7x Faster Training on DGX vs. single GPU

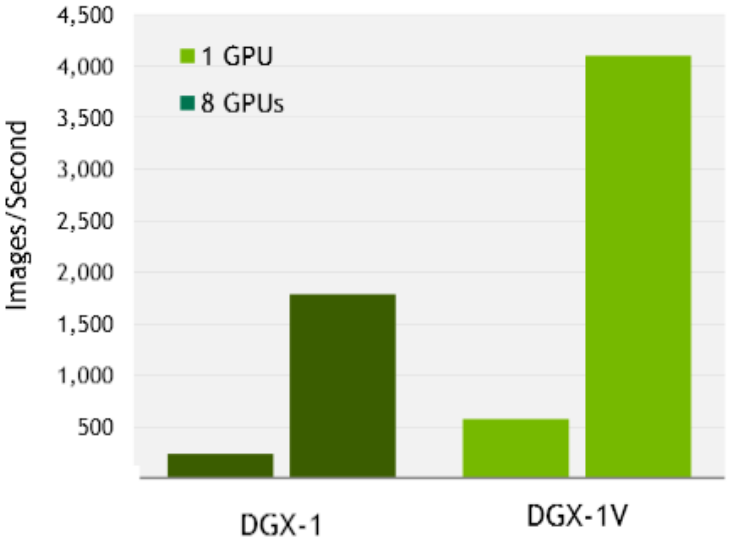


Caffe2 multi-GPU performance (images/sec) DGX-1 + cuDNN 6 (FP32), DGX-1V + cuDNN 7 (FP16). ResNet50, Batch size: 64

### Near-Linear Multi-Node Scaling

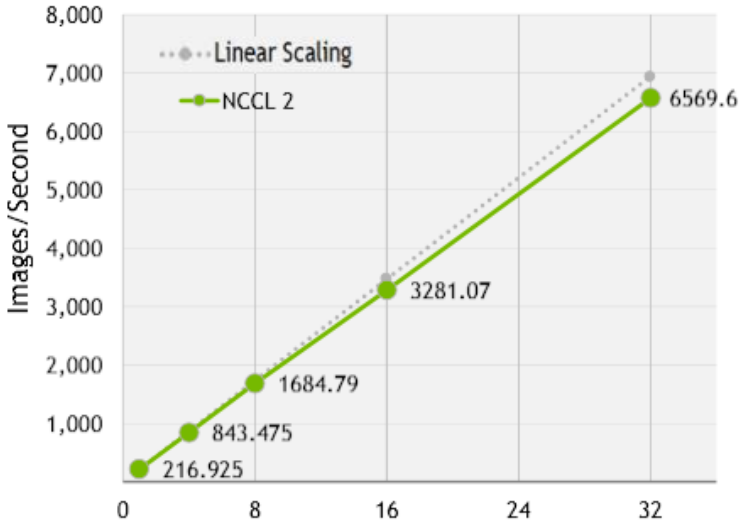


Microsoft Cognitive Toolkit multi-node scaling performance (images/sec), NVIDIA DGX-1 + cuDNN 6 (FP32), ResNet50, Batch size: 64

developer.nvidia.com/nccl

# Kakao

**Job scheduler system, GPU and Container**

add GPU resource  to Job Script.
use NVIDIA Docker for the command
…
then scheduler will do the job

```
#!/bin/bash
#PBS -l nodes=1:ppn=2
#PBS -l walltime=00:00:59
#PBS -l gpus=8
NV_GPU=$NV_GPU nvidia-docker run --net
host -e PASSWORD=root -e USERNAME=root
-e PORT=$PORT
idock.daumkakao.io/dkos/nvidia-cuda-
sshd:dev
```

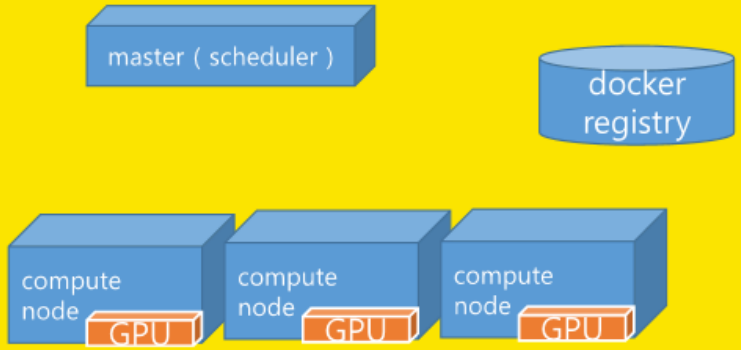

# Kakao

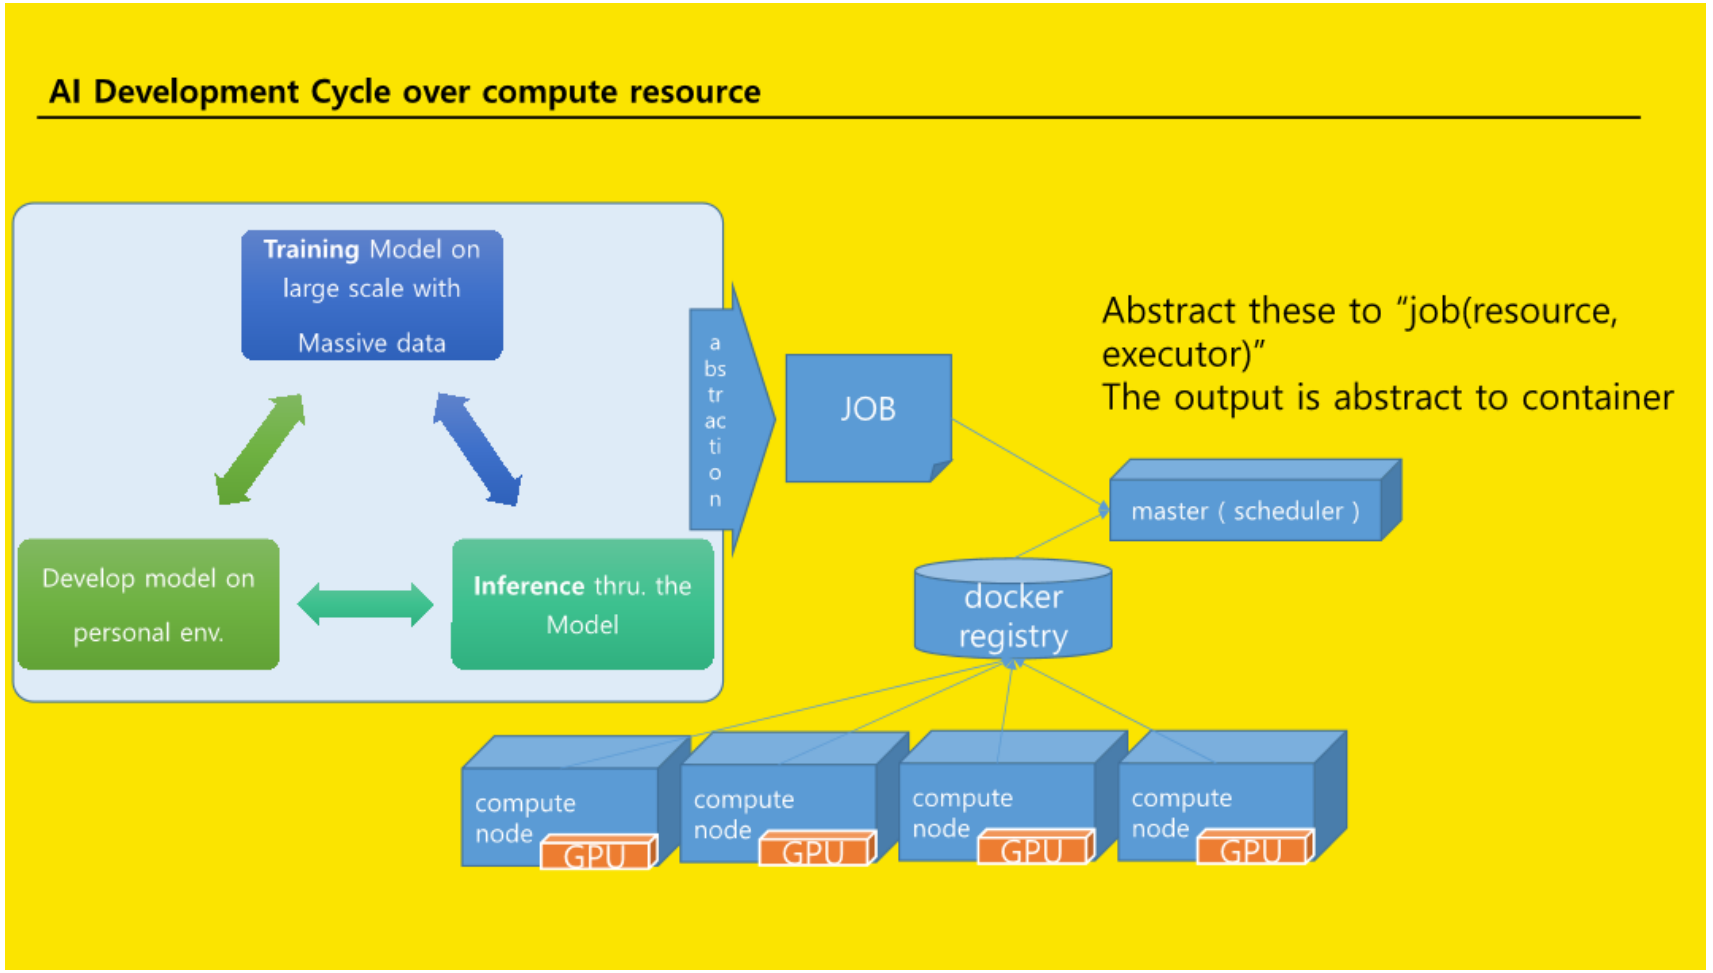
AI Development Cycle over compute resource
Training Model on large scale with Massive data
Develop model on personal env.
Inference thru. the Model
abstraction
JOB
Abstract these to "job(resource, executor)"
The output is abstract to container
master ( scheduler )
docker registry
compute node
GPU
compute node
GPU
compute node
GPU
compute node
GPU

# HOL Start

# GPU 가 항상 CPU 를 이기는가?

```
ResourceExhaustedError (see above for traceback): OOM when allocating tensor with shape[128,504,504,64]
        [[Node: conv1/Conv2D = Conv2D[T=DT_FLOAT, data_format="NHWC", padding="SAME", strides=[1, 1, 1,
1], use_cudnn_on_gpu=true, _device="/job:localhost/replica:0/task:0/gpu:0"](shuffle_batch/_383, conv1/wei
ghts/read/_381)]]
        [[Node: gradients/conv1/BiasAdd_grad/tuple/control_dependency_1/_431 = _Recv[client_terminated=f
alse, recv_device="/job:localhost/replica:0/task:0/cpu:0", send_device="/job:localhost/replica:0/task:0/g
pu:0", send_device_incarnation=1, tensor_name="edge_617_gradients/conv1/BiasAdd_grad/tuple/control_depend
ency_1", tensor_type=DT_FLOAT, _device="/job:localhost/replica:0/task:0/cpu:0"]()]]
```

- 간단한 모델의 경우 무관.
- 복잡한 모델은 GPU 의 협소한 Memory 문제로 인하여 Resource Exhausted Error 를 자주 접하게 됨.
- 이 경우 Batch Size 가 너무 작아 짐.
- Batch Size 가 너무 작아지면??? -> 이 부분은 다소 논란이 있음.

GPU의 협소한 Memory 문제로 가끔 Batch Size 를 크게 줄 수 있는 CPU 멀티 Core 의 Parallel Computation 이 필요할 때가 있음.(항상 True 는 아님. 논란이 있는 부분임)

# BigData Scale Data 정제 및 전처리가 한세월....

- Python 은 쉽고 편하지만, 굉장히 * 10  느린 언어.
- 쓰레드도 매우 원시적임.
- 병렬처리는 단독으로는 힘듦.
- 그냥 돌리면, CPU 가 24 Core 임에도, 1 Core 에서만 돈다.

- 대용량 데이터 전처리가 Model Training 보다 더 오래 걸리는 경우가 있음.
- 매일 매일 배치가 돌아야 하는 상황, 혹은 준 실시간으로 Training 주기가 잡기라도 하면, Python 만 가지고는 답 없음.

# BigData 시스템과 Deep Learning 시스템이 양분화 되어 있는 경우의 Data 이동 문제.

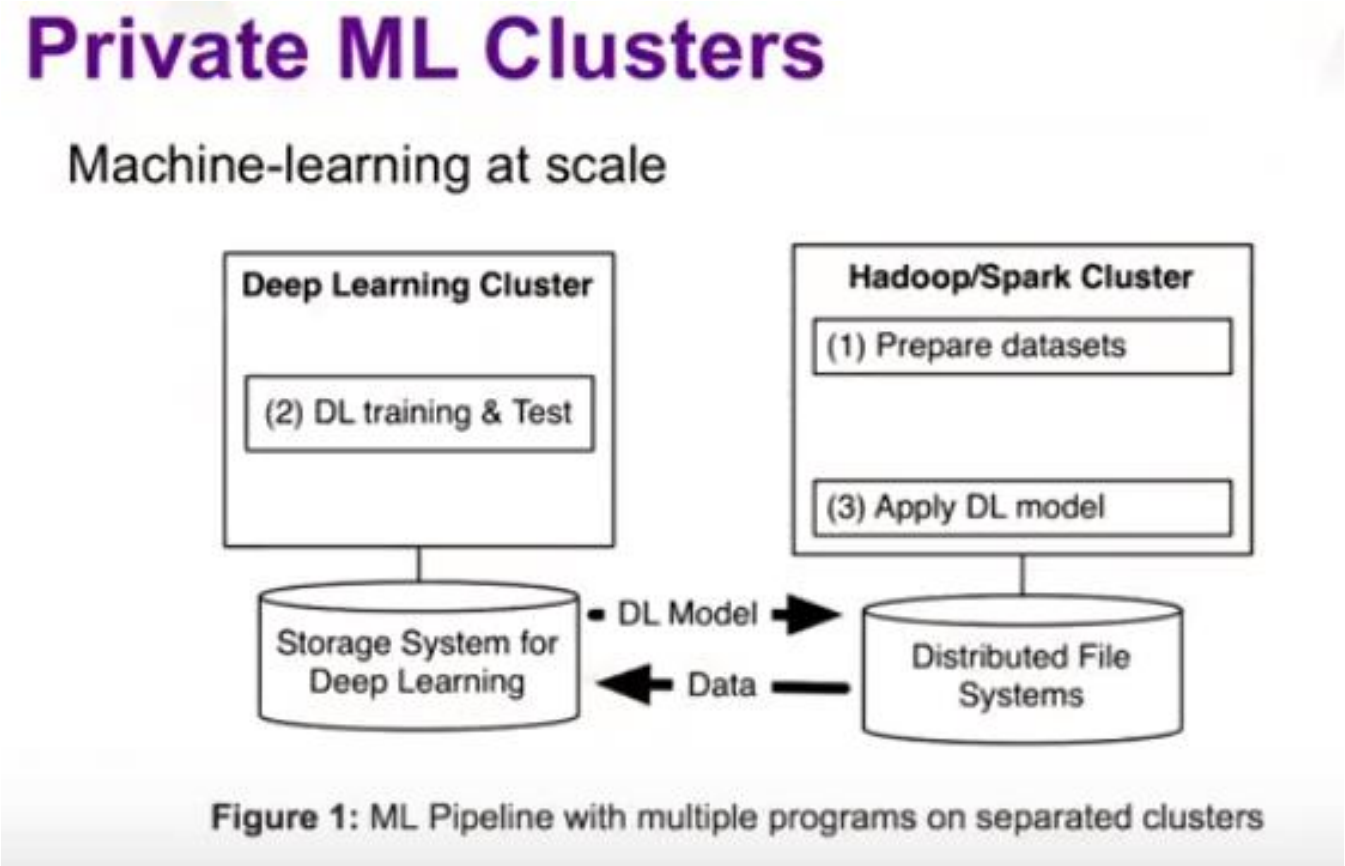


**Figure 1:** ML Pipeline with multiple programs on separated clusters

- Data Pipe Line 이 복잡하고 Data 복제 Cost 가 높다.
- 초 Large Scale 데이터는??

# 모델 개발보다 Data 전처리와 Population 문제가 더 어려운 문제인 경우가 많다.

즉, GPU 만 가지고는 Memory 문제등 한계가 있고,

속도 뿐 아니라 BigData Scale 초 대용량 Data 핸들링도 빠르고 쉽게 가능했으면 하고,

전처리 및 Population 하는데 Model 개발보다 3~4배 시간을 할애 한다면…

# SSG.COM

Zupyter on PySPark, Zupyter on Hadoop , Scala Spark or R Spark or Julia 랭귀지.

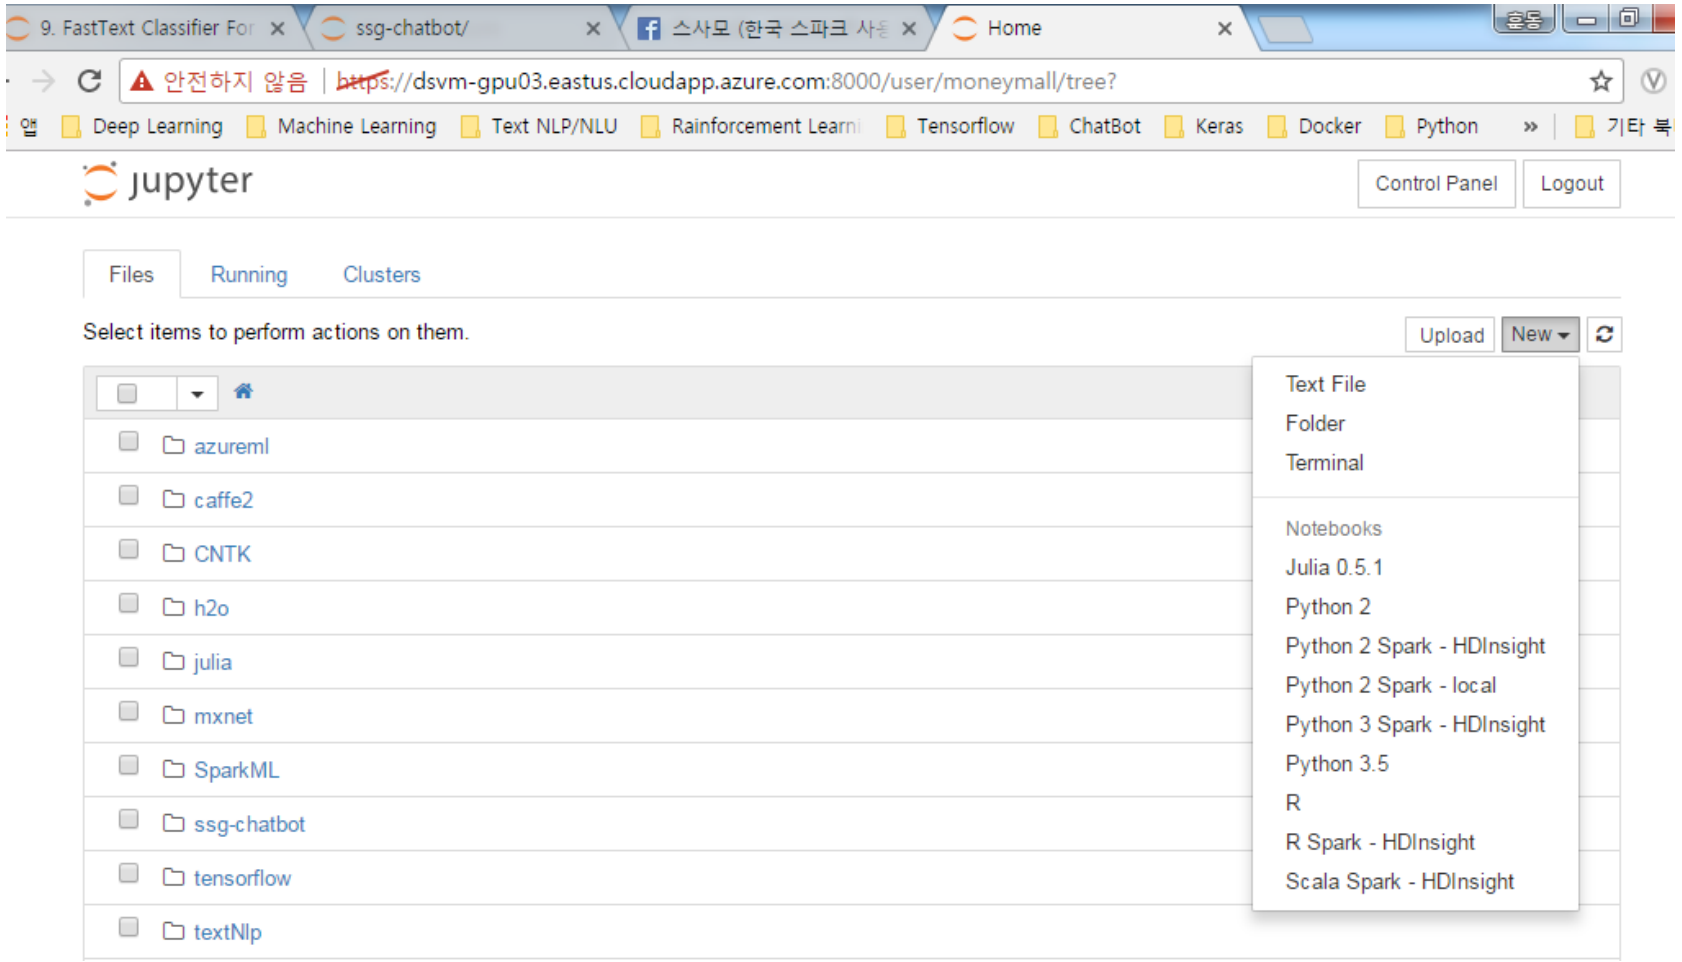

# SSG.COM

## Scikit–learn Parallel on PySpark

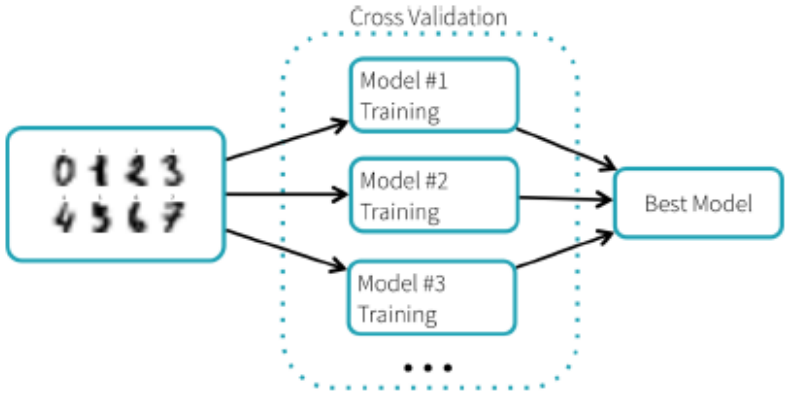


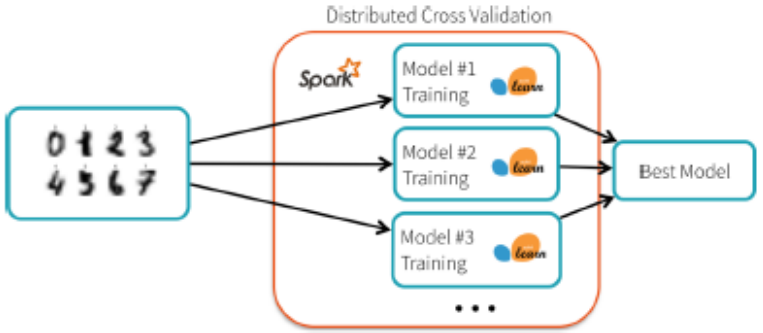


```
from sklearn import grid_search, datasets
from sklearn.ensemble import RandomForestClassifier
from sklearn.grid_search import GridSearchCV
digits = datasets.load_digits()
X, y = digits.data, digits.target
param_grid = {"max_depth": [3, None],
              "max_features": [1, 3, 10],
              "min_samples_split": [1, 3, 10],
              "min_samples_leaf": [1, 3, 10],
              "bootstrap": [True, False],
              "criterion": ["gini", "entropy"],
              "n_estimators": [10, 20, 40, 80]}
gs = grid_search.GridSearchCV(RandomForestClassifier(), param_grid=param_grid)
gs.fit(X, y)
```

```
from sklearn import grid_search, datasets
from sklearn.ensemble import RandomForestClassifier
# Use spark_sklearn's grid search instead:
from spark_sklearn import GridSearchCV
digits = datasets.load_digits()
X, y = digits.data, digits.target
param_grid = {"max_depth": [3, None],
              "max_features": [1, 3, 10],
              "min_samples_split": [1, 3, 10],
              "min_samples_leaf": [1, 3, 10],
              "bootstrap": [True, False],
              "criterion": ["gini", "entropy"],
              "n_estimators": [10, 20, 40, 80]}
gs = grid_search.GridSearchCV(RandomForestClassifier(), param_grid=param_grid)
gs.fit(X, y)
```

# SSG.COM

GPU Memory Resource 가 문제될 때는 BigData Scale Large Cluster Parallel Deep Learning Approach with BigDL

- BigDL Deep Learning Job on Hadoop Yarn Manager (by Spark Job)

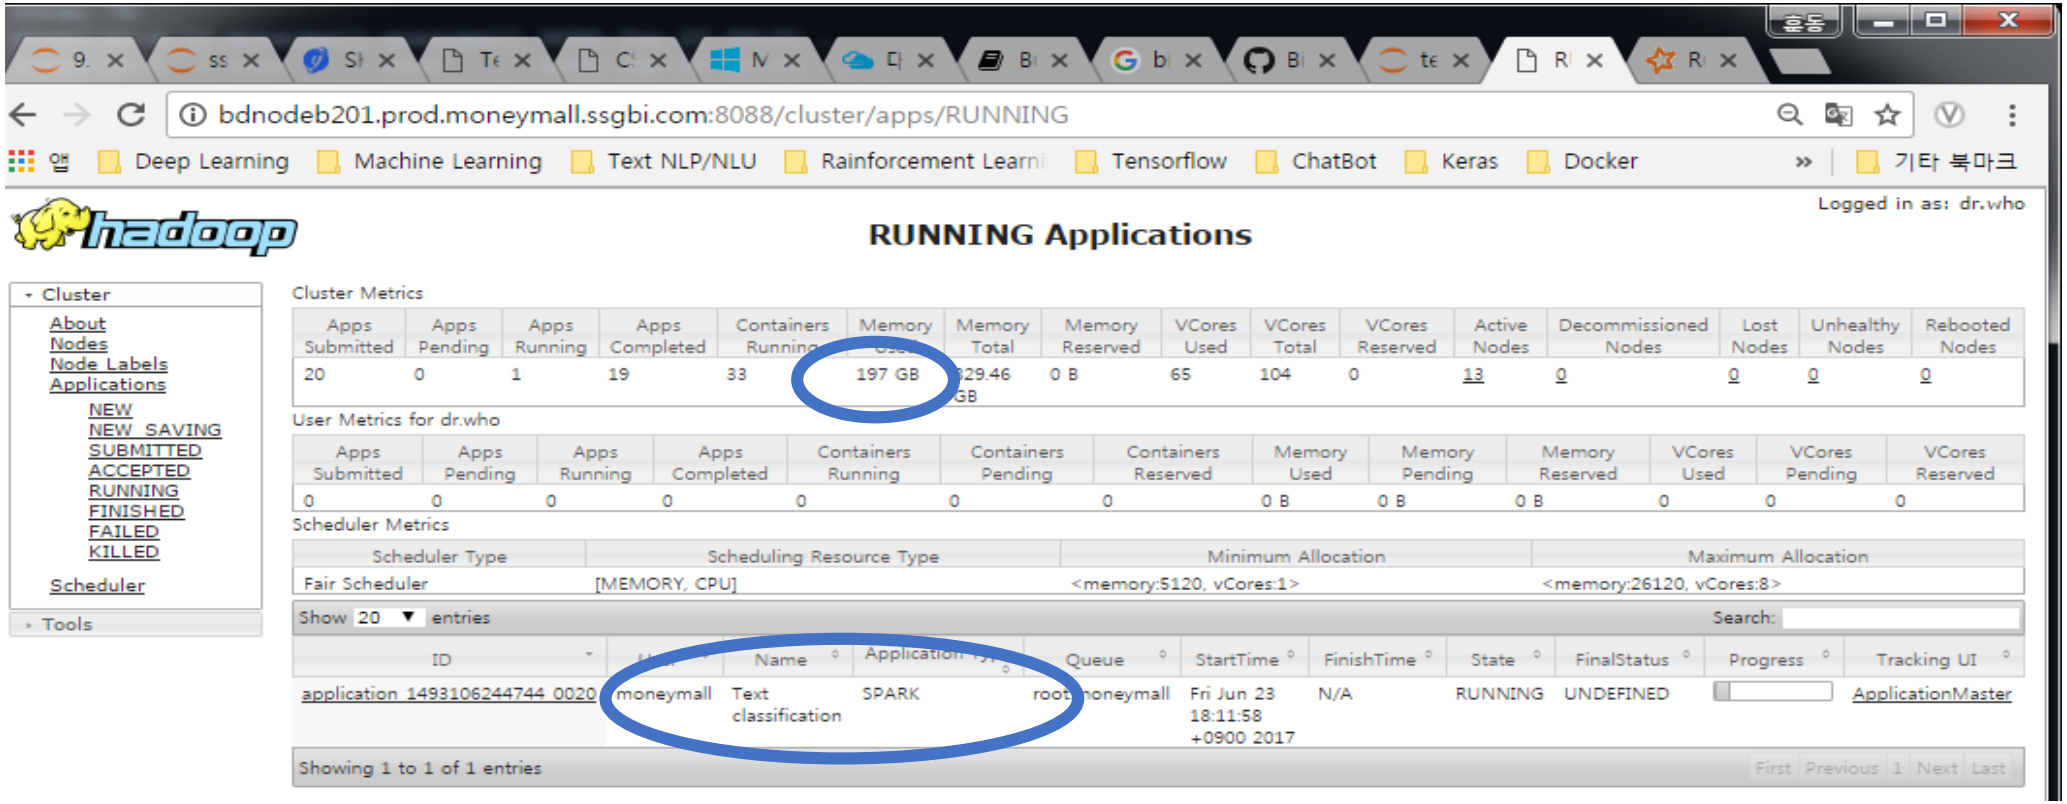

# SSG.COM

GPU Memory Resource 가 문제될 때는 BigData Scale Large Cluster Parallel Deep Learning Approach with BigDL

- BigDL Deep Learning Text Classification

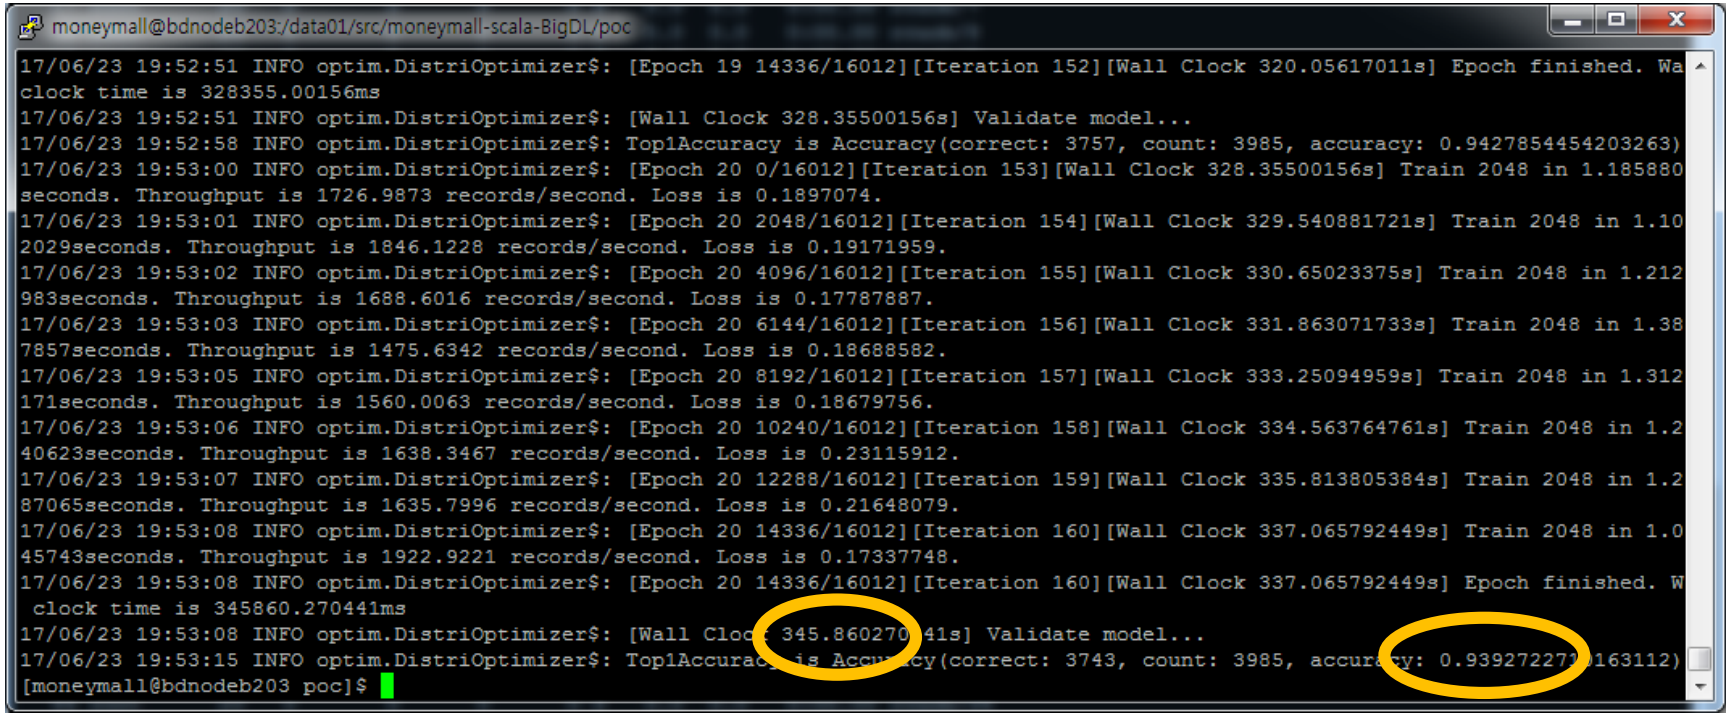

# SSG.COM

GPU Memory Resource 가 문제될 때는 BigData Scale Large Cluster Parallel Deep Learning Approach with BigDL

- BigDL Deep Learning Job on Hadoop Yarn Manager (by Spark Job)

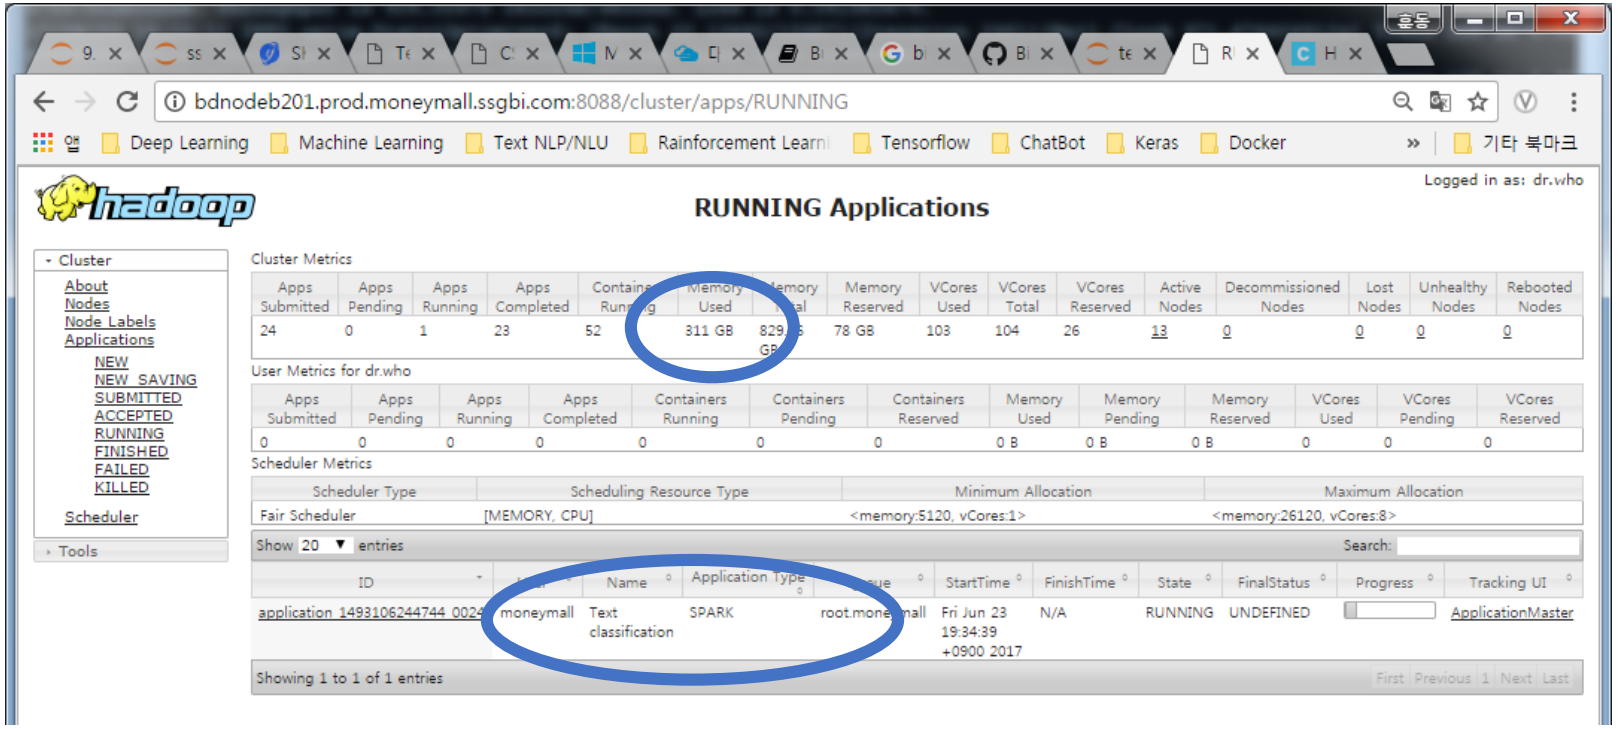

# SSG.COM

GPU Memory Resource 가 문제될 때는 BigData Scale Large Cluster Parallel Deep Learning Approach with BigDL

- BigDL Deep Learning Text Classification

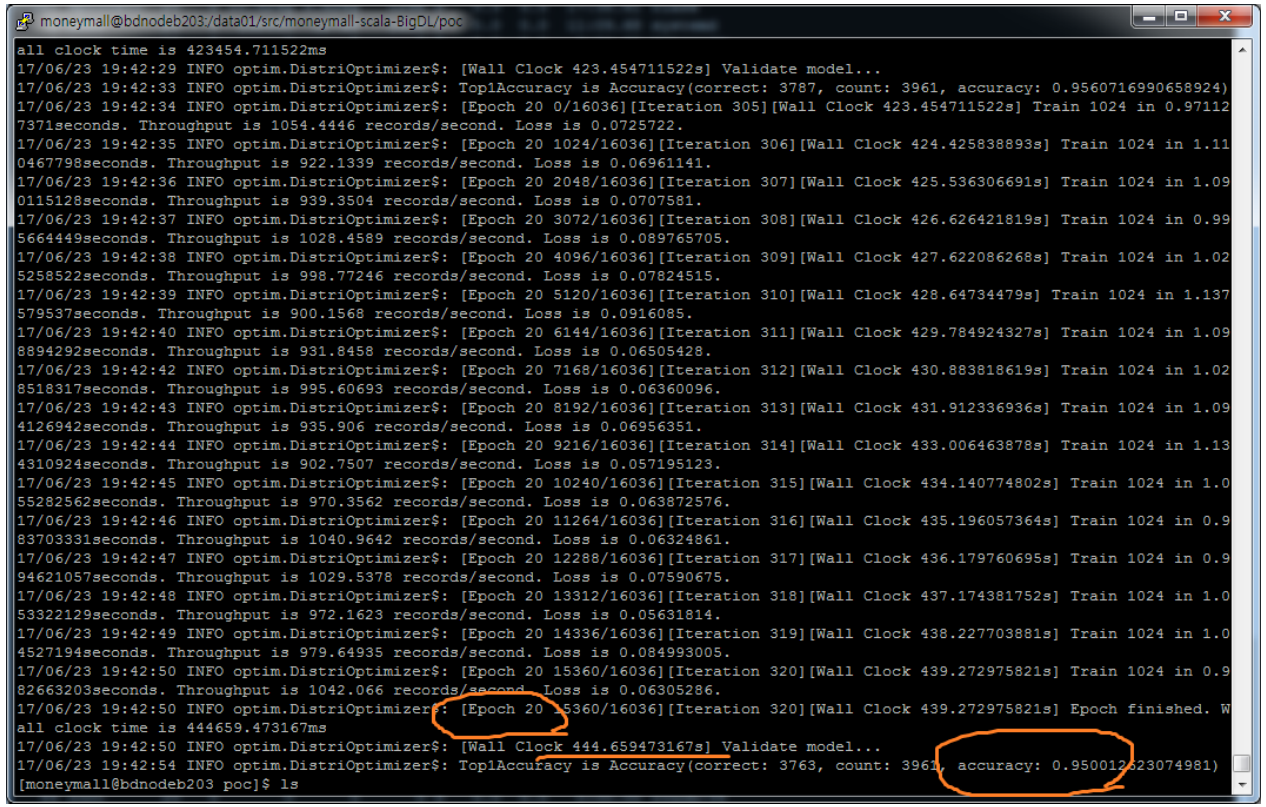

# SSG.COM

## Spark BigData Scale Deep Learning

- BigDL 예

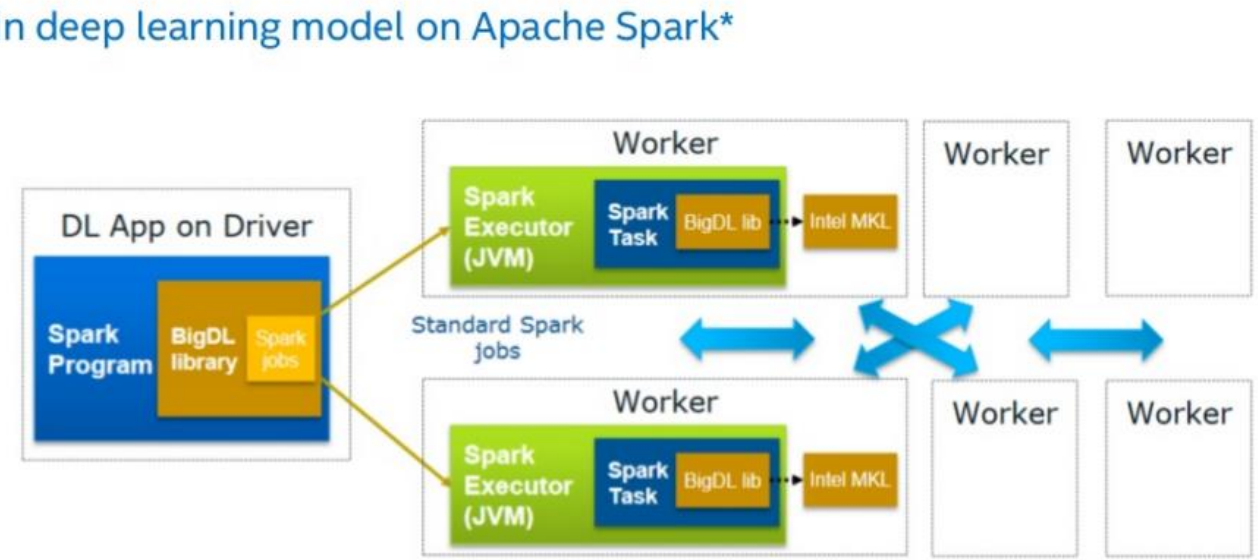

# SSG.COM

## Tenosrflow 의 Legacy 를 활용한 BigData Scale Deep Learning은?

- TensorflowOnSpark 예

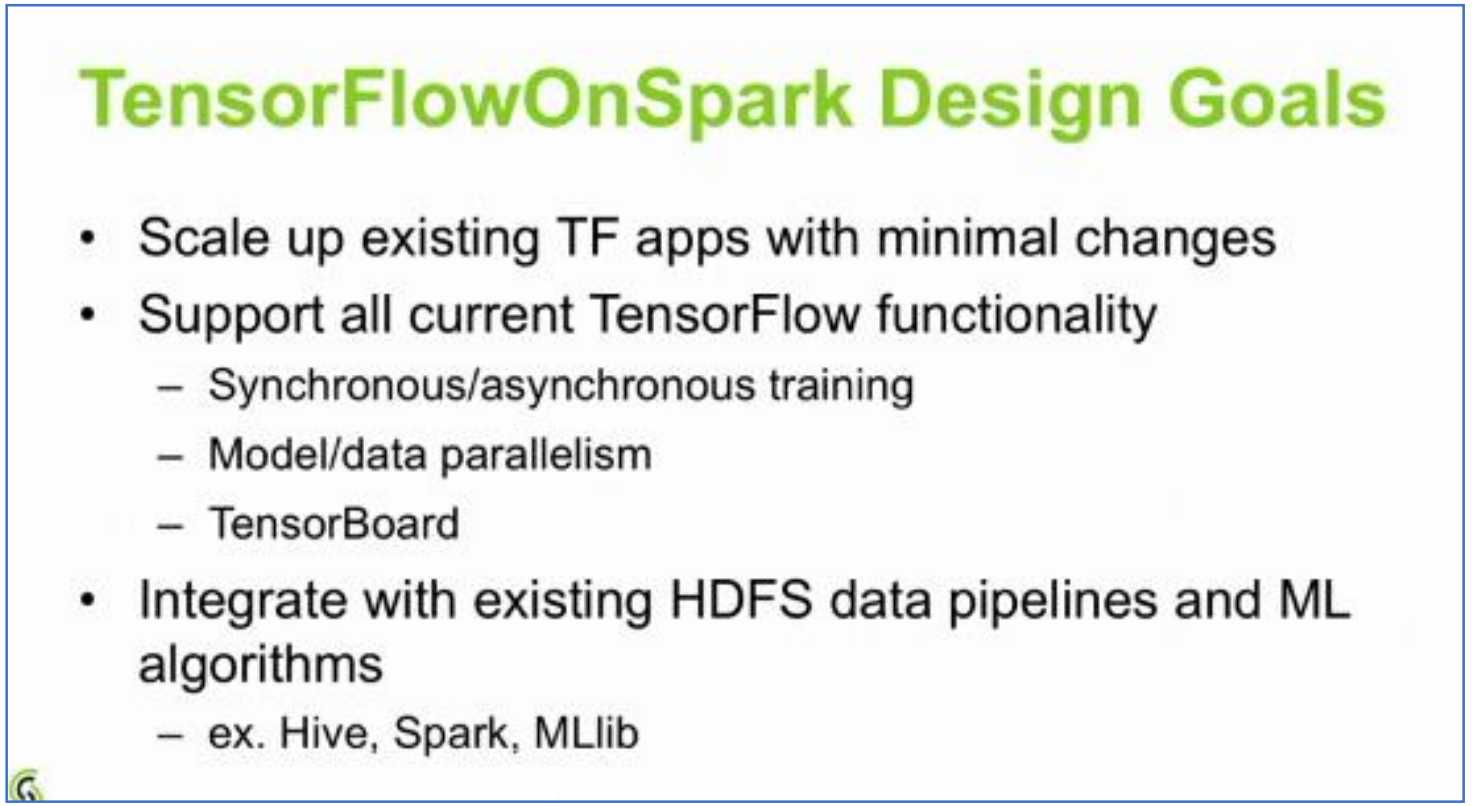

# SSG.COM
# Tenosrflow 의 Legacy 를 활용한 BigData Scale Deep Learning은?

- TensorflowOnSpark 실행 스크립트

```
# hadoop fs -rm -r mnist_model
${SPARK_HOME}/bin/spark-submit ₩
--master yarn ₩
--deploy-mode cluster ₩
--queue ${QUEUE} ₩
--num-executors 13 ₩
--executor-memory 22G ₩
--py-files ./mnist/spark/mnist_dist.py ₩
--conf spark.dynamicAllocation.enabled=false ₩
--conf spark.yarn.maxAppAttempts=1 ₩
--conf spark.executorEnv.LD_LIBRARY_PATH=$LIB_JVM:$LIB_HDFS ₩
--jars hdfs:///user/moneymall/tensorflow-hadoop-1.0-SNAPSHOT.jar ₩
./mnist/spark/mnist_spark.py ₩
--images mnist/tfr/train ₩
--format tfr ₩
--mode train ₩
--model mnist_model
# to use infiniband, add --rdma
```

# SSG.COM

## Tenosrflow 의 Legacy 를 활용한 BigData Scale Deep Learning은?

- TensorflowOnSpark 수행 결과

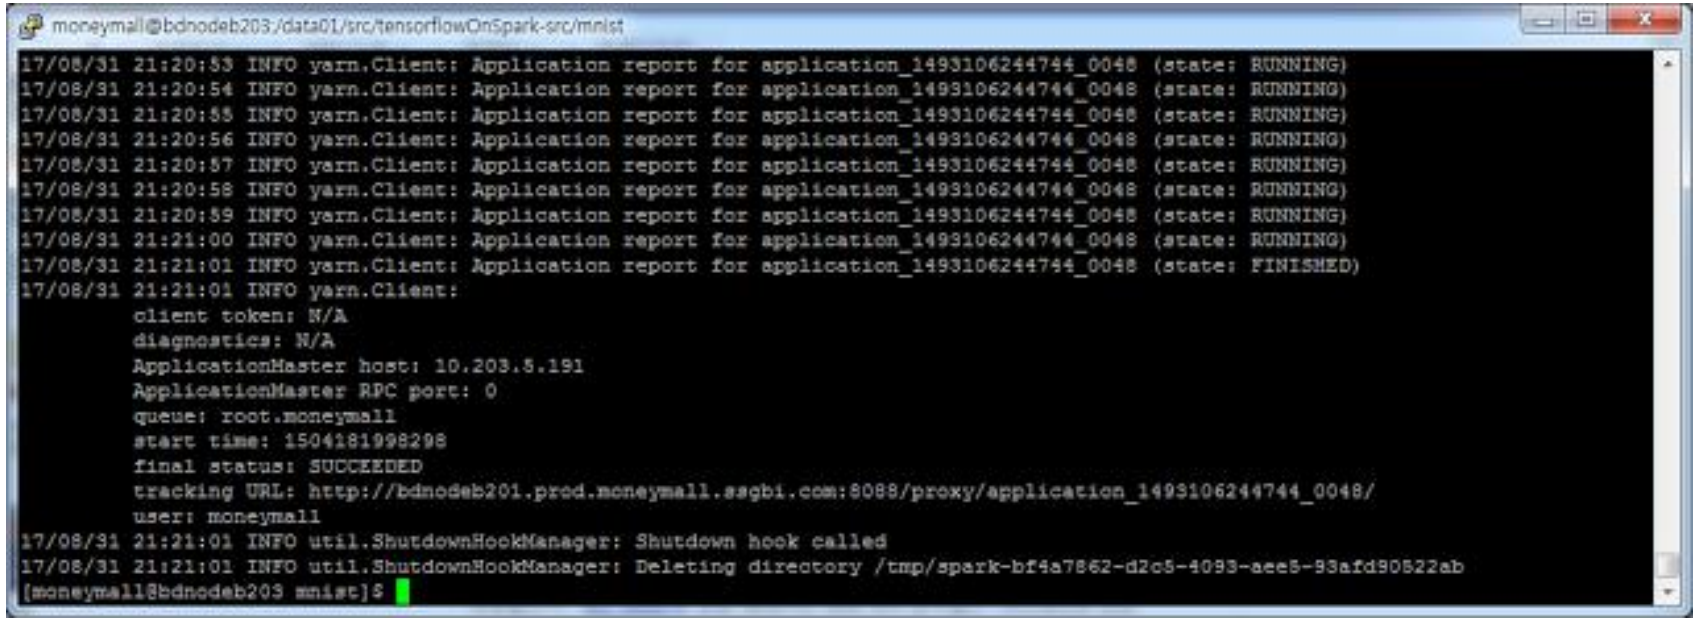

But, 모델개발이 다가 아님.

# Next...

흔한
최신 스타일
개발
Approach

2. 이 부분의
조금 쉽고 간편하
고 안전한, 접근
방법 없나?

1. 이 부분의
Pain Point &
해결방법

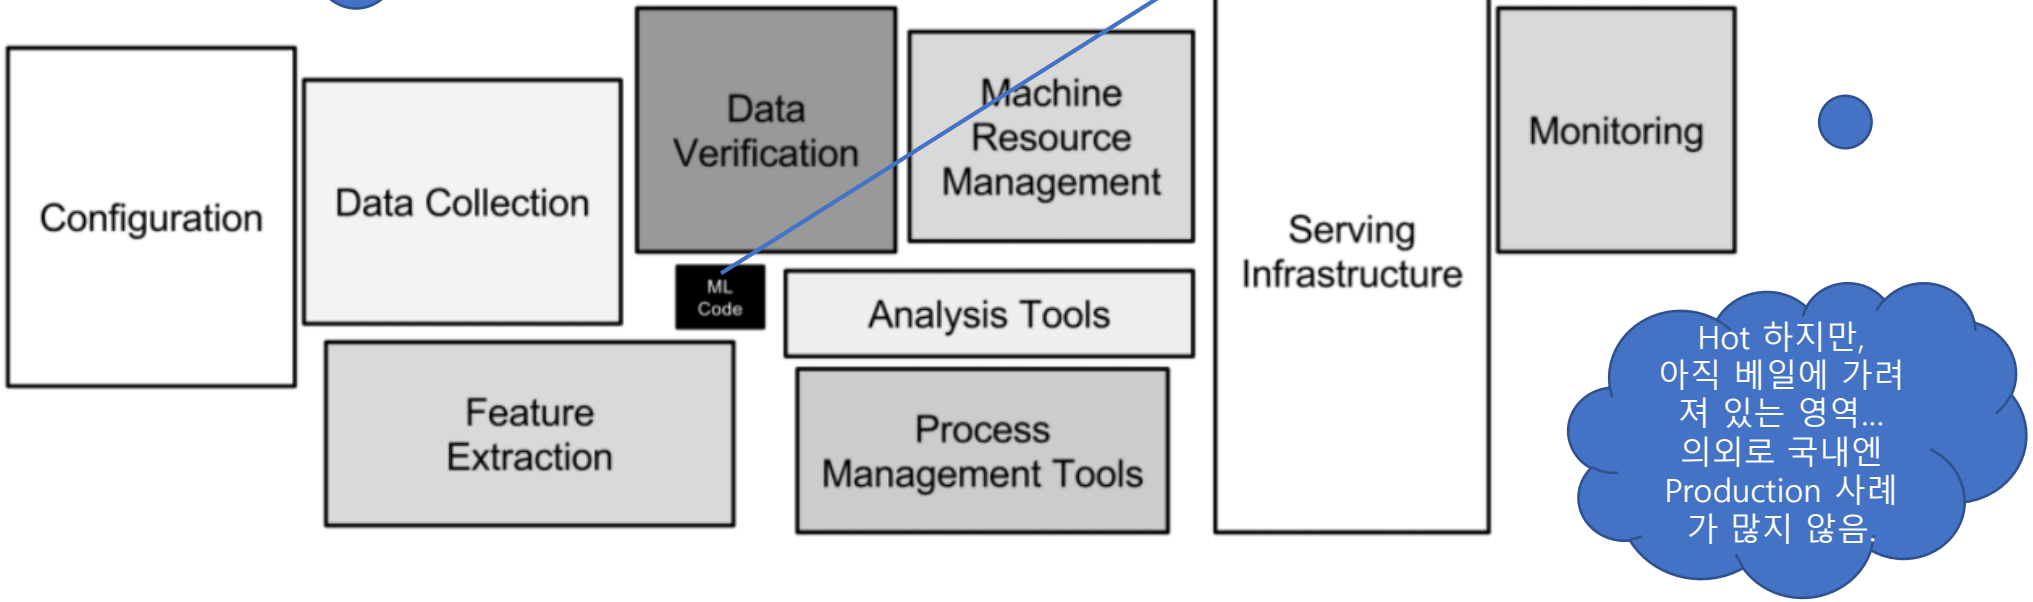


Hot 하지만,
아직 베일에 가려
져 있는 영역...
의외로 국내엔
Production 사례
가 많지 않음.

*Only a tiny fraction of the code in many ML systems is actually devoted to learning or prediction.*

Schulley et al, Hidden Technical Debt in Machine Learning Systems, In NIPS 2015.

# 전체 아키텍처

- Cloud
- Serverless
- DevOps
- AI Serving
- Auto Scale Out
- Deployment, Monitoring, Back Up, Etc ...

# 구현하고자 하는 Application Architecture

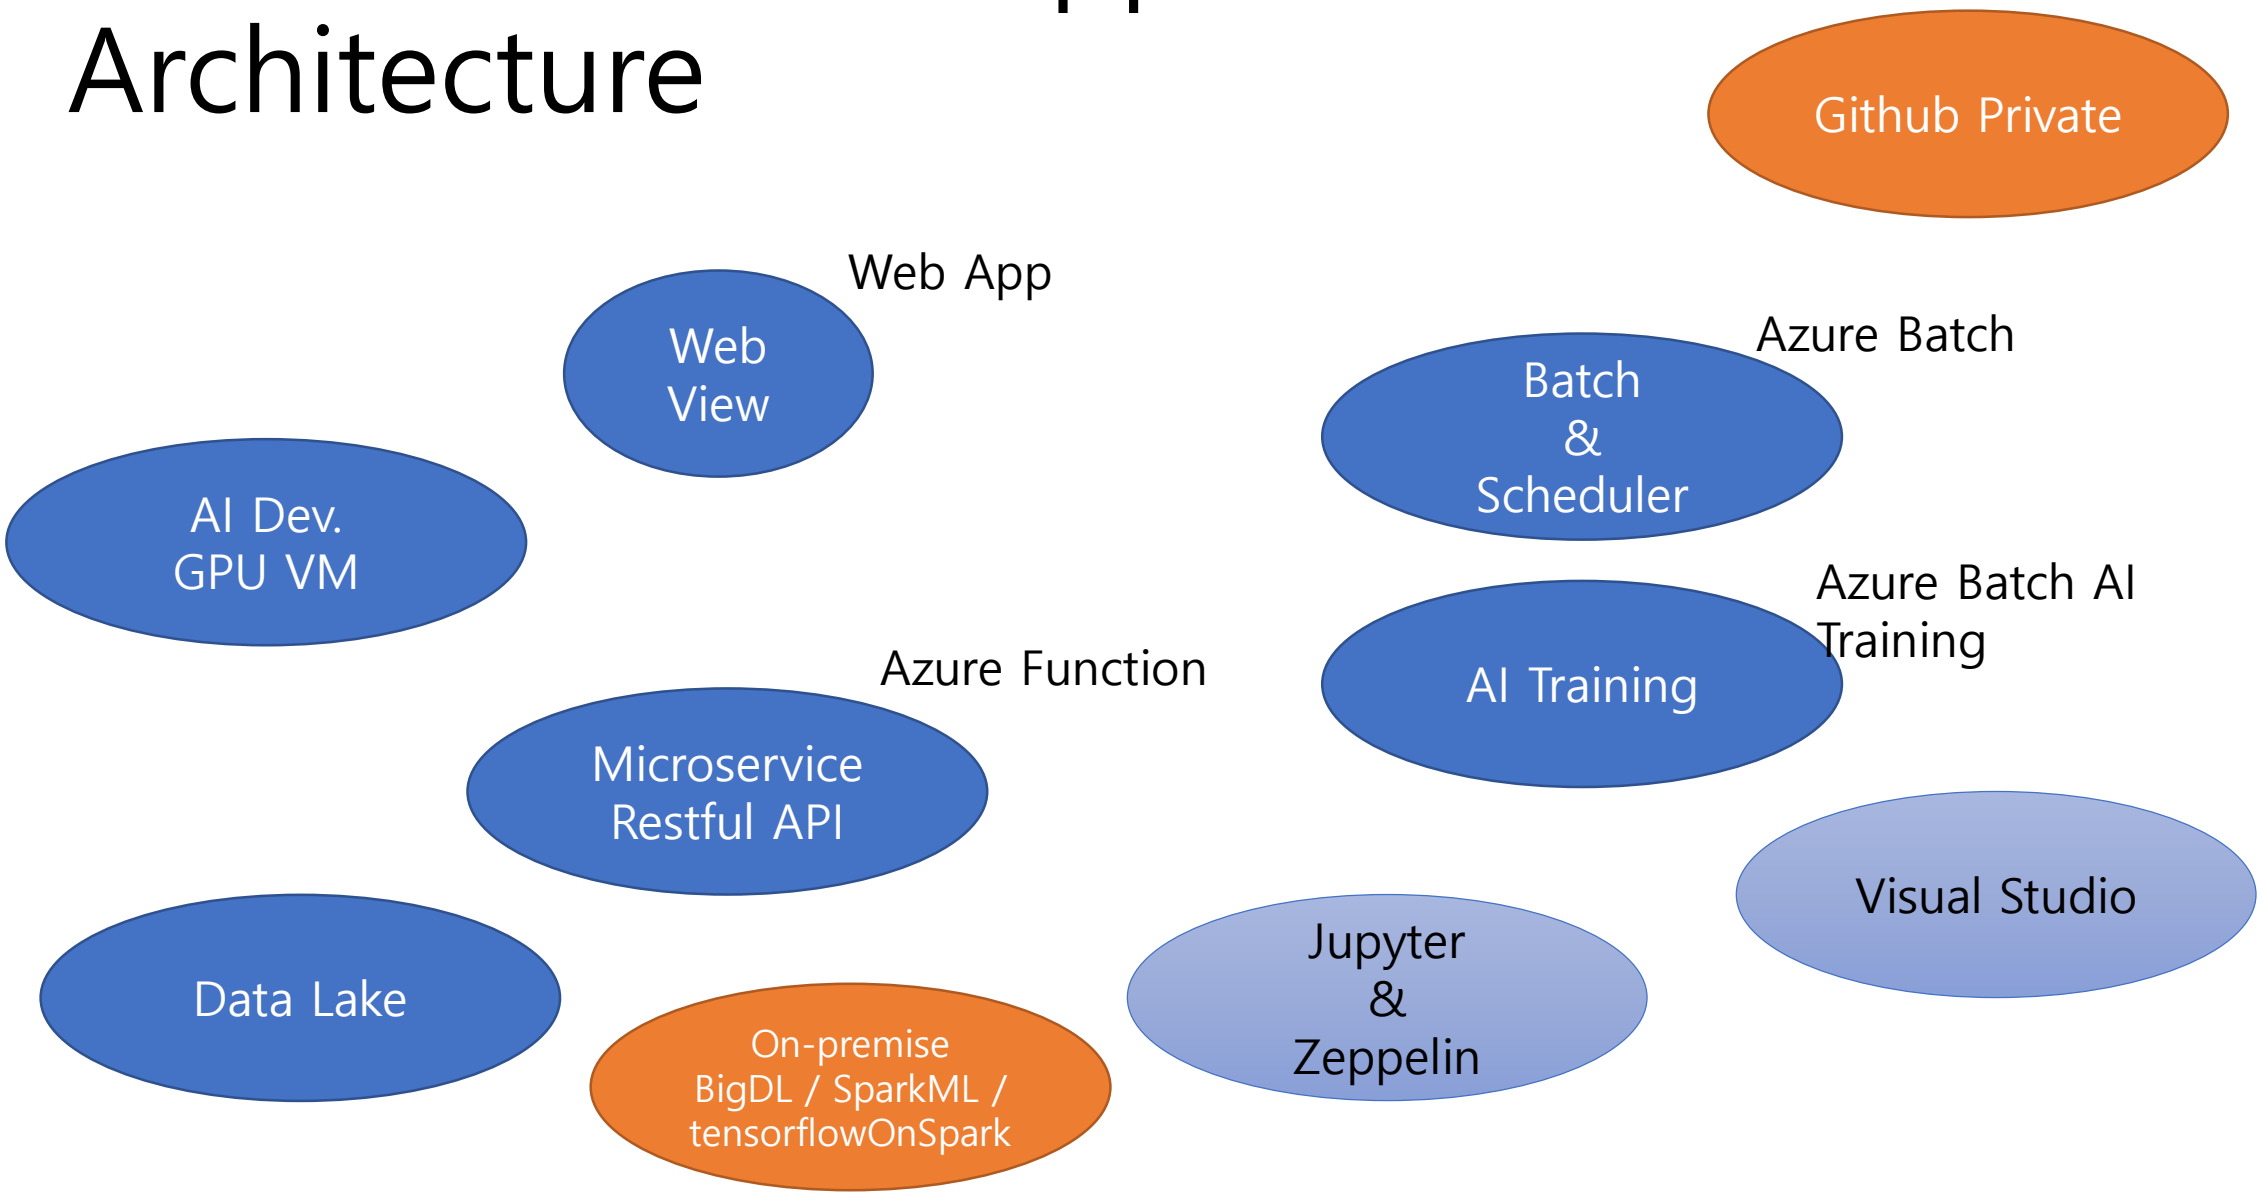

# Auto Scale Out

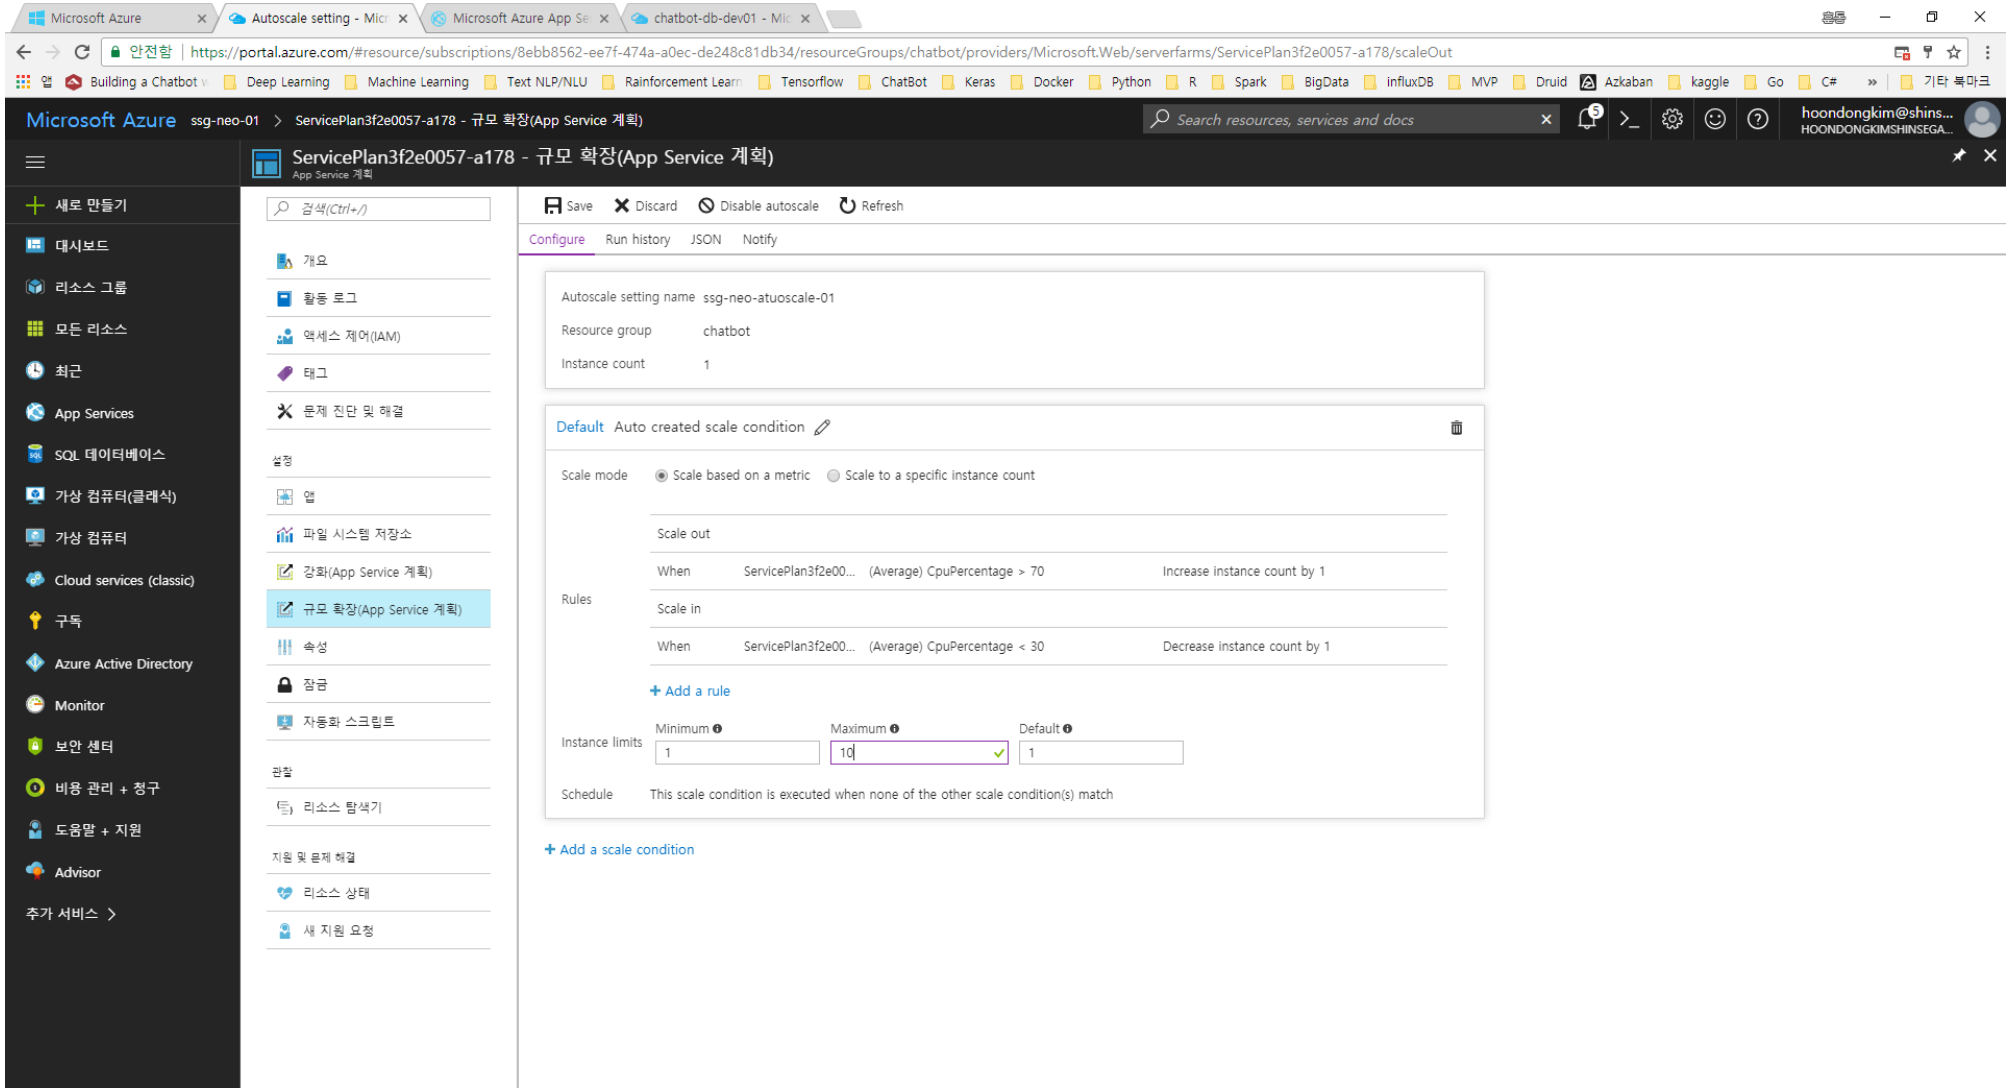

# Azure Batch

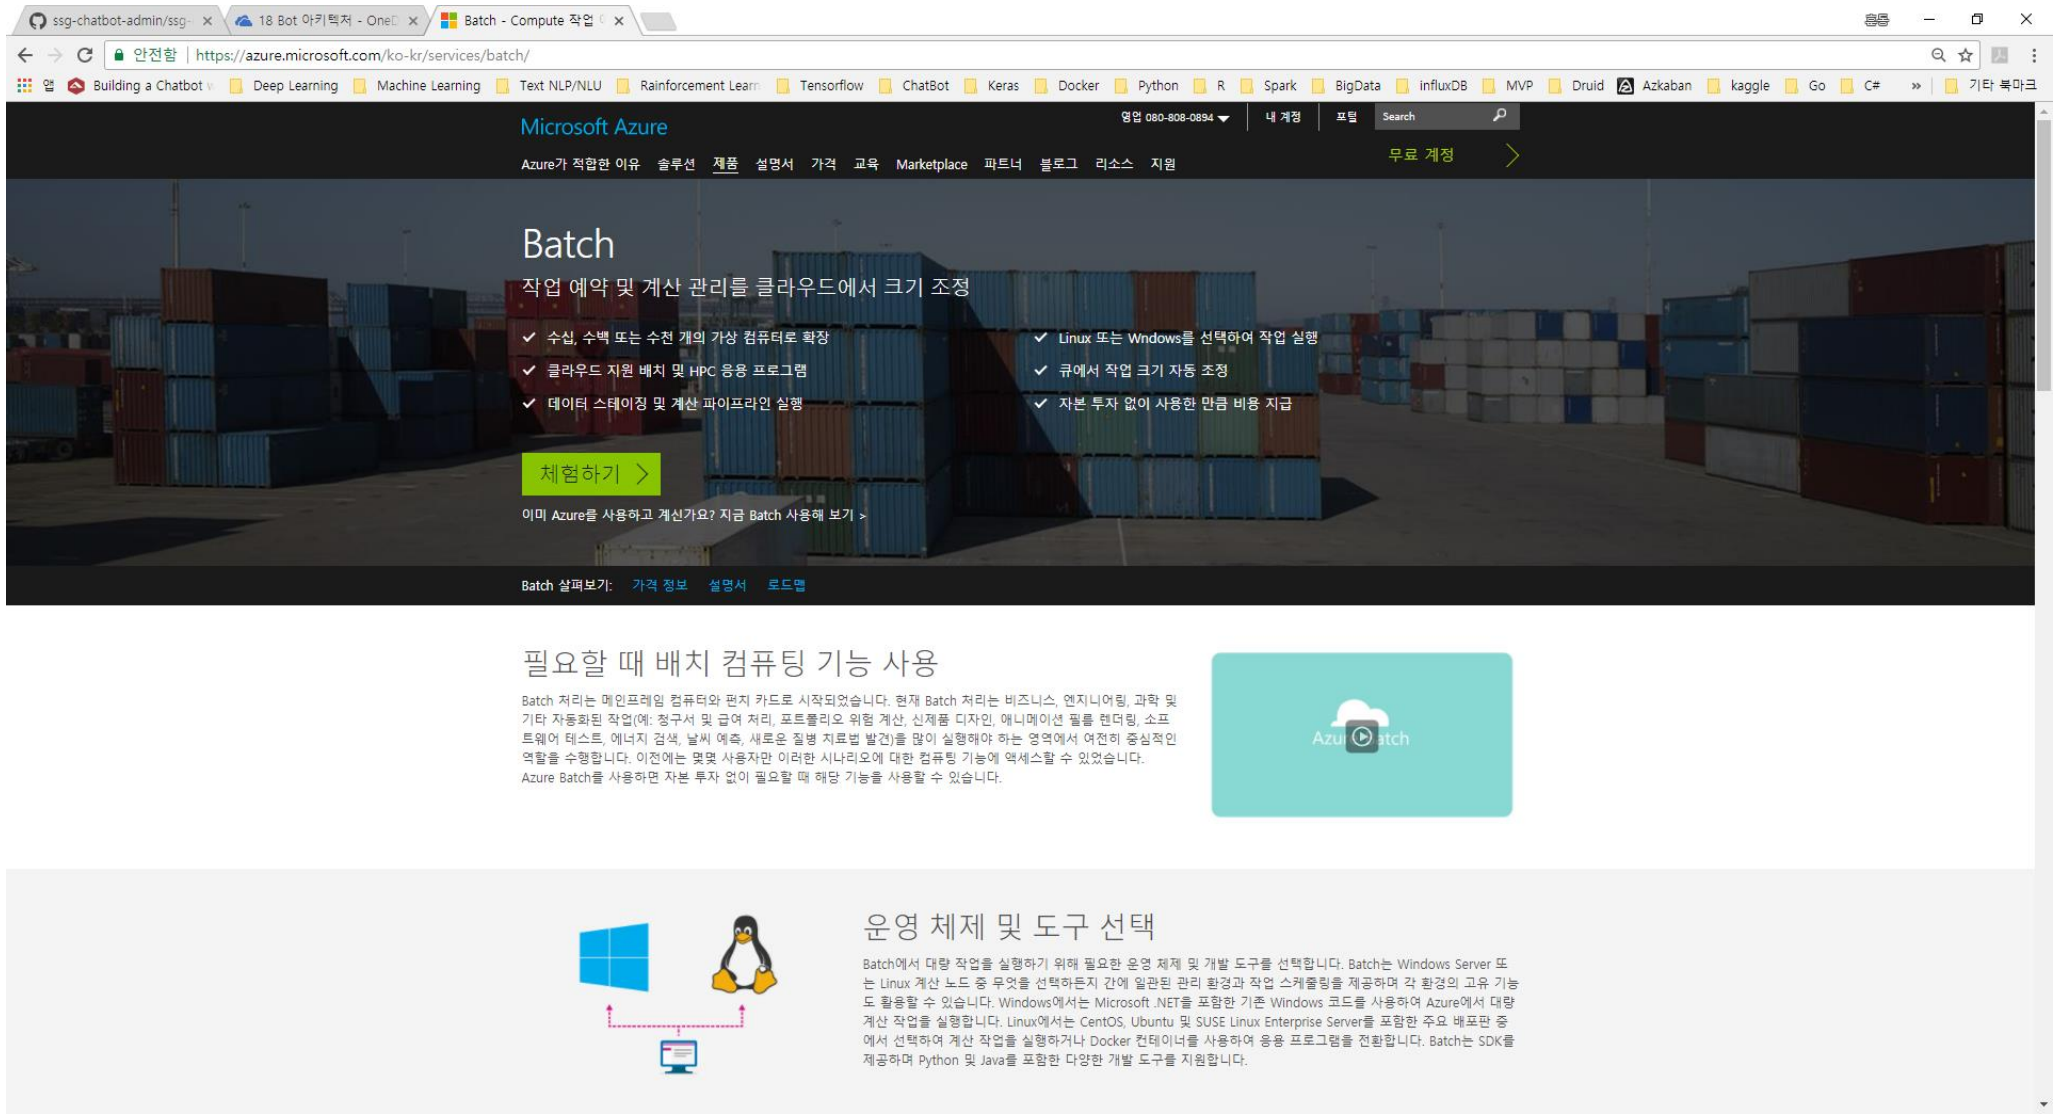
Batch - Compute 작업
https://azure.microsoft.com/ko-kr/services/batch/
Microsoft Azure
Azure가 적합한 이유 솔루션 제품 설명서 가격 교육 Marketplace 파트너 블로그 리소스 지원
무료 계정
Batch
작업 예약 및 계산 관리를 클라우드에서 크기 조정
수십, 수백 또는 수천 개의 가상 컴퓨터로 확장
클라우드 지원 배치 및 HPC 응용 프로그램
데이터 스테이징 및 계산 파이프라인 실행
Linux 또는 Wndows를 선택하여 작업 실행
큐에서 작업 크기 자동 조정
자본 투자 없이 사용한 만큼 비용 지급
체험하기
이미 Azure를 사용하고 계신가요? 지금 Batch 사용해 보기 >
Batch 살펴보기: 가격 정보 설명서 로드맵
필요할 때 배치 컴퓨팅 기능 사용
Batch 처리는 메인프레임 컴퓨터와 펀치 카드로 시작되었습니다. 현재 Batch 처리는 비즈니스, 엔지니어링, 과학 및 기타 자동화된 작업(예: 청구서 및 급여 처리, 포트폴리오 위험 계산, 신제품 디자인, 애니메이션 필름 렌더링, 소프트웨어 테스트, 에너지 검색, 날씨 예측, 새로운 질병 치료법 발견)을 많이 실행해야 하는 영역에서 여전히 중심적인 역할을 수행합니다. 이전에는 몇몇 사용자만 이러한 시나리오에 대한 컴퓨팅 기능에 액세스할 수 있었습니다. Azure Batch를 사용하면 자본 투자 없이 필요할 때 해당 기능을 사용할 수 있습니다.
운영 체제 및 도구 선택
Batch에서 대량 작업을 실행하기 위해 필요한 운영 체제 및 개발 도구를 선택합니다. Batch는 Windows Server 또는 Linux 계산 노드 중 무엇을 선택하든지 간에 일관된 관리 환경과 작업 스케줄링을 제공하며 각 환경의 고유 기능도 활용할 수 있습니다. Windows에서는 Microsoft .NET을 포함한 기존 Windows 코드를 사용하여 Azure에서 대량 계산 작업을 실행합니다. Linux에서는 CentOS, Ubuntu 및 SUSE Linux Enterprise Server를 포함한 주요 배포판 중에서 선택하여 계산 작업을 실행하거나 Docker 컨테이너를 사용하여 응용 프로그램을 전환합니다. Batch는 SDK를 제공하며 Python 및 Java를 포함한 다양한 개발 도구를 지원합니다.

# Azure Batch AI Training

https://azure.microsoft.com/ko-kr/services/batch-ai/